

第三章 大语言模型资源

由于面临着算力、数据、技术等多重挑战，从头研发或复现大语言模型绝非易事。为了持续推进大语言模型相关技术的发展，众多研发人员正致力于推动相关数据、模型以及 API 的共享或开放。本章将介绍可公开使用的大语言模型研发资源，包括模型检查点和 API (第 3.1 节)、预训练数据 (第 3.2 节)、微调数据 (第 3.3 节) 以及常用代码库 (第 3.4 节)，使读者对于相关资源有一个总体的概览。

3.1 公开可用的模型检查点或 API

众所周知，大模型预训练是一项对计算资源要求极高的任务。因此，经过预训练的公开模型检查点 (Model Checkpoint) 对于推动大语言模型技术的渐进式发展起到了至关重要的作用。得益于学术界和工业界的共同努力，目前开源社区已经积累了大量的模型检查点资源，用户可以根据自身研究或开发需求，灵活选择并下载使用这些检查点。此外，对于那些仅需利用模型进行解码生成的用户而言，商业公司提供的闭源模型的 API 接口也是一种便捷的选择。这些接口为用户提供了与模型进行交互的渠道，而无需关心模型内部的复杂结构和训练过程，即可快速获得生成结果，从而满足各种真实场景的应用需求。本部分内容将针对公开可用的模型检查点和 API 进行介绍。

3.1.1 公开可用的通用大语言模型检查点

为了方便读者根据自身资源预算以及使用需求来选择适合的模型，下面将针对部分代表性的大语言模型进行介绍，主要关注讨论模型的参数量大小、训练过程所需的数据资源和算力资源、模型所采用的独特技术以及其在实际应用中的性能评估情况等。关于更多模型的总结详见表 3.1。

- *LLaMA* 和 *LLaMA-2*. *LLaMA* [34] 是 Meta AI 在 2023 年 2 月发布的一系列大语言模型，有 7B、13B、30B 和 65B 四种参数规模版本，是当时性能非常优异的开源模型之一，直到目前也仍然被广泛使用与对比。其中，13B 参数的版本在部分自然语言处理基准测试中超越了具有 175B 参数的 GPT-3 模型。*LLaMA* 各个参数量版本都在超过 1T 词元的预训练语料上进行了训练，其中 65B 参数的模型

版本在 2,048 张 80G 显存的 A100 GPU 上训练了近 21 天。由于对公众开放了模型权重且性能优秀，LLaMA 已经成为了最受欢迎的开源大语言模型之一，许多研究工作都是以其为基座模型进行微调或继续预训练，衍生出了众多变体模型（详见第 3.1.2 节），极大地推动了大语言模型领域的研究进展。2023 年 7 月，Meta AI 公开发布了 LLaMA-2 [58]，对第一代模型进行了综合升级。LLaMA-2 有 7B、13B、34B（未开源）和 70B 四种参数规模版本，并且可用于商用。相比于第一版 LLaMA，LLaMA-2 扩充了预训练的词元量（达到了 2T），同时将模型的上下文长度翻了一倍（达到 4,096 个词元），并引入了分组查询注意力机制（详见第 5.2.5 节）等技术来提升模型性能。此外，Meta AI 使用 LLaMA-2 作为基座模型，通过进一步的有监督微调、基于人类反馈的强化学习等技术对模型进行迭代优化，完整经历了“预训练-有监督微调-基于人类反馈的强化学习”这一训练流程，并发布了面向对话应用的微调系列模型 LLaMA-2 Chat（同样具有四种参数规模的版本）。LLaMA-2 Chat 不仅在许多任务上具有更好的模型性能（例如代码生成、世界知识、阅读理解和数学推理），同时在应用中也更加安全。

- *ChatGLM*. ChatGLM [59, 60] 是智谱 AI 和清华大学联合开发的中英双语对话式模型，最早发布于 2023 年 5 月，并一直进行迭代优化，目前已经更新到了 ChatGLM-3。ChatGLM 系列模型参数量都是 6B，具备流畅对话的能力且部署门槛低，在语义、数学、推理、代码、知识等不同角度的评测中都取得了优异表现。除此之外，该系列还开源了基础模型 ChatGLM3-6B-Base、长文本对话式模型 ChatGLM3-6B-32K 和进一步强化了对于长文本理解能力的 ChatGLM3-6B-128K。除了 ChatGLM 系列，智谱 AI 还致力于开发更强更大规模的 GLM-4。

- *Falcon*. Falcon [61] 是阿布扎比的技术创新研究院（TII）发布的一系列语言模型，包括 7B、40B 和 180B 三个参数版本，两个较小的版本发布于 2023 年 5 月，180B 参数的版本发布于 2023 年 9 月。其中，180B 参数的版本是当时参数量最大的开源预训练语言模型。Falcon 的训练数据 80% 以上来自 RefinedWeb 数据集，该数据集是一个基于 Common Crawl 的经过严格清洗的网页数据集。根据 Falcon 的技术报告，其 7B 版本的模型在 384 张 A100 上使用了 1.5T 词元进行训练，40B 版本的模型在 384 张 A100 上使用了 1T 词元进行训练，而 180B 版本的模型在 4,096 张 A100 上使用了 3.5T 词元进行训练。同样地，TII 也开放了经过指令微调的模型 Falcon Instruct 供用户使用。

- *Baichuan* 和 *Baichuan-2*. Baichuan [62] 是百川智能公司于 2023 年 6 月发布的

开源可商用大语言模型，参数规模为 7B，支持中英双语，预训练数据规模达到了 1.2T 词元。当时在其比较的中文和英文的多个基准测试中都取得了同尺寸模型较优效果。2023 年 9 月，百川智能发布了新一代开源多语言模型 Baichuan-2 [63]，目前有 7B 和 13B 两种参数规模，预训练数据规模达到了 2.6T 词元。除了基座模型，百川智能也提供了经过有监督微调和人类偏好对齐的对话式模型。根据 Baichuan-2 的技术报告，Baichuan-2 性能进一步提升，在其评估基准测试上的表现全面超过 Baichuan。此外，Baichuan-2 还具备优秀的多语言能力和垂域应用潜力（如法律、医疗等领域）。

- *InternLM* 和 *InternLM-2*. InternLM [64] 是上海人工智能实验室开发的多语言开源大模型，于 2023 年 7 月公开发布，目前已开源 7B 和 20B 两种参数规模。据 InternLM 的技术报告，20B 参数的 InternLM 在其评估的基准测试上达到了第一代 LLaMA (70B) 的水平，并且支持数十类插件，有较强的工具调用能力。除了开源模型本体外，InternLM 还提供了配套的开源工具体系，包括预训练框架 InternLM-Train、低成本微调框架 XTuner、部署推理框架 LMDeploy、评测框架 OpenCompass 以及面向场景应用的智能体框架 Lagent，为用户使用提供了完备的使用链。2024 年 1 月，InternLM-2 [65] 正式发布，相比于 InternLM，各个方面的能力都有了提升，包括推理、代码、数学、对话、指令遵循等众多能力。InternLM-2 目前提供了 1.8B、7B 和 20B 三种参数规模的版本可供使用。此外，InternLM 系列也发布了多模态模型 InternLM-XComposer 和数学模型 InternLM-Math。

- *Qwen*. Qwen [66] 是阿里巴巴公司开源的多语大模型系列，首次公开发布于 2023 年 8 月，且仍在继续更新。现有从 0.5B 到 72B 的不同参数规模版本，其中，14B 的 Qwen 的预训练数据规模达到了 3T 词元。根据 Qwen 的技术报告，2024 年 2 月最新发布的 Qwen-1.5 (72B) 在其评估的测试基准上优于 LLaMA-2 (70B) 的表现，在语言理解、推理、数学等方面均展现出了优秀的模型能力。除此之外，Qwen 系列专门为代码、数学和多模态设计了专业化模型 Code-Qwen、Math-Qwen 和 Qwen-VL，以及对应的对话式模型，可以供用户进行选择使用。

- *Mistral*. Mistral [67] 是 Mistral AI 在 2023 年 9 月公开发布的具有 7B 参数的大语言模型，受到了广泛关注。根据 Mistral 博客提供的结果，Mistral (7B) 在其评估的基准测试中都优于 LLaMA-2 (13B) 和 LLaMA (34B)，并且在代码生成方面的表现接近于专门为代码任务微调的 Code LLaMA (7B)。在解码效率上，Mistral 采用了分组查询注意力技术（详见第 5.2.5 节）；在上下文长度上，Mistral 采用了滑

动窗口注意力技术（详见第 5.2.5 节），增强了对长文本的处理能力。通过引入分组查询注意力和滑动窗口注意力技术，Mistral 在 16K 序列长度和 4K 注意力窗口大小下速度提升了 2 倍。除此之外，Mistral AI 还发布了 Mistral 的有监督微调版本——Mistral Instruct，在 MT-bench [68]（评估大语言模型在多轮对话和指令遵循能力的基准测试）上优于很多 7B 参数的对话模型。

- *DeepSeek LLM*. DeepSeek LLM [69] 是幻方公司于 2023 年 11 月公开发布的大语言模型，主要支持中英双语，目前有 7B 和 67B 两种参数规模，预训练阶段使用的数据量都达到了 2T 规模的词元。根据 DeepSeek LLM 的技术报告，67B 参数量的 DeepSeek LLM 在多个评估的基准测试中超过了 LLaMA-2 (70B) 模型，特别是在代码、数学和推理任务上。DeepSeek LLM 同时提供 7B 和 67B 两种参数规模的对话模型，并针对人类价值观进行了对齐。除了通用基座模型，DeepSeek 系列也发布了相应的数学模型 DeepSeek-Math、代码模型 DeepSeek-Coder 和多模态模型 DeepSeek-VL。

- *Mixtral*. Mixtral [67] 全称为 Mixtral 8×7B，是 Mistral AI 在 2023 年 12 月公开发布的稀疏混合专家模型架构的大语言模型，这也是较早对外公开的 MoE 架构的语言模型。在结构上，Mixtral 包含 8 组不同的“专家”参数，对于每个词元，Mixtral 的每一层都会通过路由网络选择两组“专家”来对其进行处理，并将它们的输出相加结合起来。虽然 Mixtral 一共有 46.7B 参数，但是每个词元在处理过程中只会用到 12.9B 参数，因此其处理速度和资源消耗与 12.9B 参数的模型相当。在性能上，Mistral AI 博客提供的结果显示，Mixtral 在多个基准测试中都超过了 LLaMA-2 (70B) 和 GPT-3.5，并且解码速度比 LLaMA-2 (70B) 快了 6 倍，能够支持 32K 长度的上下文。此外，Mixtral 还支持多种语言，包括英语、法语、意大利语、德语和西班牙语等。Mistral AI 同样也发布了 Mixtral 8×7B 有监督微调版本——Mixtral 8×7B Instruct，在 MT-bench [68] 上取得了与 GPT-3.5 相当的性能表现。

- *Gemma*. Gemma [70] 是谷歌于 2024 年 2 月发布的轻量级开源大模型，有 2B 和 7B 两种参数规模。Gemma 的技术路线与谷歌另一款闭源多模态模型 Gemini [71] 类似，但 Gemma 为纯语言模型，且专注于英语任务。Gemma (2B) 预训练数据规模达到了 2T 词元，而 Gemma (7B) 的预训练数据规模达到了 6T 词元，两者的预训练语料都主要是英语数据。根据 Gemma 的技术报告显示，Gemma 在其评估的多个自然语言基准测试中都取得了较好水平。同样地，Gemma 也提供了有监督微调版本 Gemma IT，并与人类偏好进行了对齐。

- *MiniCPM*. MiniCPM [72] 是面壁智能与清华大学共同研发的开源语言模型，仅有 2B 的参数规模，于 2024 年 2 月发布。MiniCPM 在训练前进行了模型沙盒实验，通过预先使用小模型广泛实验寻找更优的训练设置，并最终迁移至大模型上。在训练方法上，MiniCPM 首先采用了稳定训练与退火的两阶段学习方法，然后进行了有监督微调和人类偏好对齐。根据 MiniCPM 的技术报告，在其评测的多个领域基准测试中取得了非常优异的效果。同系列模型还包括 MiniCPM-2B-SFT（指令微调版本）、MiniCPM-2B-DPO（DPO 对齐版本）、MiniCPM-V（多模态模型）等。

- *YuLan-Chat*. YuLan-Chat [73] 是中国人民大学研发的中英双语系列对话模型，最早发布于 2023 年 6 月，目前已经更迭至最新版本 YuLan-Chat-3。其中，YuLan-Chat-1 在 LLaMA 的基础上进行微调，使用了精心优化的高质量中英文混合指令，发布了 13B 和 65B 两个参数规模版本。YuLan-Chat-2 在 LLaMA-2 的基础上使用中英双语进行继续预训练，同样具有 13B 和 65B 两个参数版本，目前可支持 8K 的上下文长度。YuLan-Chat-3 从头开始进行了完整的预训练，其参数规模为 12B，预训练词元数达到 1.68 T，具体训练流程可以参考第 4.4.3 节。YuLan-Chat-3 采用了两阶段的课程学习指令微调方法，并且进行了人类对齐。

3.1.2 LLaMA 变体系列

自 2023 年 2 月发布以来，LLaMA 系列模型在学术界和工业界引起了广泛的关注，对于推动大语言模型技术的开源发展做出了重要贡献。在上述内容中，我们已经介绍了 LLaMA 系列模型的概况。LLaMA 拥有较优的模型性能，并方便用户公开获取，因此一经推出就迅速成为了最受欢迎的开放性语言模型之一。众多研究人员纷纷通过指令微调或继续预训练等方法来进一步扩展 LLaMA 模型的功能和应用范围。其中，指令微调由于相对较低的计算成本，已成为开发定制化或专业化模型的首选方法，也因此出现了庞大的 LLaMA 家族。本书根据指令微调所使用的指令类型，对现有的 LLaMA 变体模型进行简单的梳理介绍。

- **基础指令**. 在 LLaMA 的扩展模型中，Stanford Alpaca [42] 是第一个基于 LLaMA (7B) 进行微调的开放式指令遵循模型。通过使用 Self-Instruct 方法 [74] 借助大语言模型进行自动化的指令生成，Stanford Alpaca 生成了 52K 条指令遵循样例数据 (Alpaca-52K) 用于训练，其指令数据和训练代码在随后的工作中被广泛采用。Vicuna [75] 作为另一个流行的 LLaMA 变种，也受到了广泛关注。它并没有使用合成指令数据，主要是使用 ShareGPT 收集的用户日常对话数据进行训练，展现

表 3.1 近年来大语言模型的统计数据，包括预训练数据规模（以词元数量或存储大小表示）和硬件条件等。本表仅列举有公开论文介绍技术细节的模型，其中“发布时间”表示相应论文或技术报告正式发布的日期。“可公开获取”表示模型检查点可以公开获取，而“闭源”则相反。“适配”指模型是否经过了后续微调：IT 表示指令微调，RLHF 表示基于人类反馈的强化学习。

可公开获取 模型	发布 时间	大小 (B)	适配		预训练 数据规模	硬件 (GPUs / TPUs)	训练 时间
T5	2019.10	11	-	-	1000B 词元	1024 TPU v3	-
CodeGen	2022.03	16	-	-	577B 词元	-	-
OPT	2022.05	175	-	-	180B 词元	992 A100 (80G)	-
CodeGeeX	2022.09	13	-	-	850B 词元	1536 Ascend 910	60 天
GLM	2022.10	130	-	-	400B 词元	768 A100 (40G)	60 天
BLOOM	2022.11	176	✓	-	366B 词元	384 A100 (80G)	105 天
Galactica	2022.11	120	-	-	106B 词元	-	-
LLaMA	2023.02	65	-	-	1400B 词元	2048 A100 (80G)	21 天
Pythia	2023.04	12	-	-	300B 词元	256 A100 (40G)	-
CodeGen-2	2023.05	16	-	-	400B 词元	-	-
StarCoder	2023.05	15.5	-	-	1000B 词元	512 A100 (40G)	-
Falcon	2023.06	180	-	-	3500B 词元	4096 A100 (40G)	-
LLaMA-2	2023.07	70	✓	✓	2000B 词元	2000 A100 (80G)	-
Baichuan-2	2023.09	13	✓	✓	2600B 词元	1024 A800	-
QWEN	2023.09	14	✓	✓	3000B 词元	-	-
FLM	2023.09	101	✓	-	311B 词元	192 A800	22 天
Mistral	2023.09	7	✓	-	-	-	-
Skywork	2023.10	13	-	-	3200B 词元	512 A800 (80G)	-
Mixtral	2023.12	47	✓	-	-	-	-
DeepSeek	2024.01	67	✓	✓	2000B 词元	-	-

闭源模型	发布 时间	大小 (B)	适配		预训练 数据规模	硬件 (GPUs / TPUs)	训练 时间
GPT-3	2020.05	175	-	-	300B 词元	-	-
Codex	2021.07	12	-	-	100B 词元	-	-
ERNIE 3.0	2021.07	10	-	-	375B 词元	384 V100	-
FLAN	2021.09	137	✓	-	-	128 TPU v3	60 小时
Yuan 1.0	2021.10	245	-	-	180B 词元	2128 GPU	-
Anthropic	2021.12	52	-	-	400B 词元	-	-
WebGPT	2021.12	175	-	✓	-	-	-
Gopher	2021.12	280	-	-	300B 词元	4096 TPU v3	920 小时
LaMDA	2022.01	137	-	-	768B 词元	1024 TPU v3	57.7 天
MT-NLG	2022.01	530	-	-	270B 词元	4480 A100 (80G)	-
AlphaCode	2022.02	41	-	-	967B 词元	-	-
InstructGPT	2022.03	175	✓	✓	-	-	-
Chinchilla	2022.03	70	-	-	1400B 词元	-	-
PaLM	2022.04	540	-	-	780B 词元	6144 TPU v4	-
GPT-4	2023.03	-	✓	✓	-	-	-
PanGu-Σ	2023.03	1085	-	-	329B 词元	512 Ascend 910	100 天
PaLM-2	2023.05	16	✓	-	100B 词元	-	-

了基于 LLaMA 的语言模型在对话生成任务中的优秀实力。

- 中文指令. 原始的 LLaMA 模型的训练语料主要以英语为主, 在中文任务上的表现比较一般。为了使 LLaMA 模型能够有效地支持中文, 研究人员通常会选择扩展原始词汇表, 在中文数据上进行继续预训练, 并用中文指令数据对其进行微调。经过中文数据的训练, 这些扩展模型不仅能更好地处理中文任务, 在跨语言处理任务中也展现出了强大的潜力。目前常见的中文大语言模型有 Chinese LLaMA、Panda、Open-Chinese-LLaMA、Chinese Alpaca、YuLan-Chat 等。

- 垂域指令. LLaMA 虽然展现出了强大的通用基座模型能力, 但是在特定的垂直领域 (例如医学、教育、法律、数学等) 的表现仍然较为局限。为了增强 LLaMA 模型的垂域能力, 很多工作基于搜集到的垂域相关的指令数据, 或者采用垂域知识库以及相关专业文献等借助强大的闭源模型 API (例如 GPT-3.5、GPT-4 等) 构建多轮对话数据, 并使用这些指令数据对 LLaMA 进行指令微调。常见的垂域 LLaMA 模型有 BenTsao (医学)、LAWGPT (法律)、TaoLi (教育)、Goat (数学)、Comucopia (金融) 等。

- 多模态指令. 由于 LLaMA 模型作为纯语言模型的强大能力, 许多的多模态模型都将其 (或将其衍生模型) 作为基础语言模型, 搭配视觉模态的编码器, 使用多模态指令对齐视觉表征与文本。与其他语言模型相比, Vicuna 在多模态语言模型中受到了更多的关注, 由此形成了一系列基于 Vicuna 的多模态模型, 包括 LLaVA、MiniGPT4、InstructBLIP 和 PandaGPT。

除了使用不同种类的指令数据进行全参数微调外, 研发人员还经常使用轻量化微调的技术训练 LLaMA 模型变体, 以降低训练成本, 方便用户部署。例如, AlpacaLoRA [76] 使用 LoRA 复现了 Stanford Alpaca。LLaMA 模型系列的发布有力地推动了大语言模型技术的发展。为了更直观地展示 LLaMA 系列模型的研究进展以及衍生模型之间的关系, 图 3.1 展示了一个 LLaMA 系列模型的简要演化图, 呈现了 LLaMA 模型系列从发布到快速发展以及在各个领域中的广泛应用。由于衍生模型的数量庞大, 这里无法将所有相关模型纳入到图中。为了支持增量更新, 我们共享了该图的原文件, 并欢迎读者在我们提供的 GitHub 仓库上传来更新所需要添加的模型。




图 3.1 LLaMA 系列模型的衍生工作进化图（图片来源：[10]）

3.1.3 大语言模型的公共 API

上述主要介绍了开源大语言模型的情况，目前性能最强大的模型仍然主要以闭源为主。这些闭源模型通过 API（应用程序接口）形式进行调用，无需在本地运行模型即可使用。在闭源大语言模型领域，OpenAI 无疑是最具代表性和影响力的公司，为此本书整理了 OpenAI 目前提供的常用 API 服务，帮助读者了解选用。

- 语言模型 API. 目前最常用的 GPT 系列模型 API 包括 GPT-3.5 Turbo、GPT-4 和 GPT-4 Turbo。其中，GPT-3.5 Turbo 对应的 API 接口为 `gpt-3.5-turbo`，支持 16K 词元的上下文长度。目前，开发者可以使用自己的数据来微调 GPT-3.5 Turbo，以便更好地适用于个性化的应用场景，例如提高模型的指令遵循能力、定制化输出格式以及定制化语气等；GPT-4 是一个多模态模型，也是目前 GPT 系列效果最好的模型，其对应的 API 接口有 `gpt-4`（基础版本，没有视觉功能）、`gpt-4-32k`（将上下文长度扩展到 32K）、`gpt-4-vision-preview`（带有视觉功能的 GPT-4 多模态版本）。相较于 GPT-4，GPT-4 Turbo 有更快的生成速度、更长的上下文窗口（最多 128K）以及更低的价格，其最新对应的 API 为 `gpt-4-turbo-preview`。对于许多基本任务来说，GPT-4 和 GPT-3.5 模型之间的差异并不显著。然而，在较为复杂的推理任务中，GPT-4 能够展现出更为强大的模型能力。值得注意的是，OpenAI

一直在维护和升级这些模型接口，因此 API 名称实际上将指向最新版本。详细的用法请参阅官网指南¹。

- 文本表征 API. 除了语言模型 API 外，OpenAI 还提供用于文本表征的 API，可用于聚类、稠密信息检索等多种下游任务，可以为知识检索以及检索增强生成提供支持。目前 OpenAI 主要提供三种文本表征的 API 接口，包括 `text-embedding-ada-002`、`text-embedding-3-small` 以及 `text-embedding-3-large`。其中，`text-embedding-ada-002` 发布于 2022 年，至今模型并未更新，可以提供 1,536 维的向量表征，在英文文本表征基准测试 MTEB 获得了 61% 的平均得分；`text-embedding-3-small` 是一个更高效的文本表征模型，同样提供 1,536 维的向量表征。相对于 `text-embedding-ada-002`，`text-embedding-3-small` 有较大的性能提升，在 MTEB 的平均得分达到 62.3%；而 `text-embedding-3-large` 能够支持高达 3,072 维的向量表征，是三者中目前性能最好的模型，在 MTEB 的平均得分达到了 64.6%。这三个 API 支持的输入长度都是 8,191 个词元，开发者可根据自身需求选择合适的 API。

3.2 常用的预训练数据集

与早期的预训练语言模型相比，大语言模型需要更多的训练数据，这些数据需要涵盖广泛的内容范围。多领域、多源化的训练数据可以帮助大模型更加全面地学习真实世界的语言与知识，从而提高其通用性和准确性。本节将介绍目前常用于训练大语言模型的代表性数据集合。根据其内容类型进行分类，这些语料库可以划分为：网页、书籍、维基百科、代码以及混合型数据集。

3.2.1 网页

网页是大语言模型训练语料中最主要的数据来源，包含了丰富多样的文本内容，例如新闻报道、博客文章、论坛讨论等，这些广泛且多元的数据为大语言模型深入理解人类语言提供了重要资源。下面介绍重要的网页数据资源。

通用网页数据

首先介绍面向各种语言（主要以英文为主）的通用网页数据集合。

¹<https://platform.openai.com/docs/models/overview>

表 3.2 常用语料库信息表

语料库	类型	大小	机构	最近更新时间
Common Crawl	通用网页	-	Common Crawl	-
C4	通用网页	800GB	Google	2019 年 04 月
CC-Stories-R	通用网页	31GB	-	2019 年 09 月
CC-NEWS	通用网页	78GB	Facebook	2019 年 02 月
REALNEWS	通用网页	120GB	University of Washington	2019 年 04 月
RedPajama-Data	通用网页	100TB	Together AI	2023 年 10 月
RefinedWeb	通用网页	1.68TB	TII	2023 年 01 月
WanJuan-CC	通用网页	400GB	上海人工智能实验室	2024 年 02 月
OpenWebText	通用网页	38GB	-	2023 年 03 月
ChineseWebText	中文网页	1.42TB	中科院自动化所	2023 年 11 月
WanJuan 1.0 Text	中文网页	1TB	上海人工智能实验室	2023 年 08 月
WuDaoCorpora Text	中文网页	5TB	北京智源研究院	2021 年 06 月
SkyPile-150B	中文网页	620GB	昆仑万维	2023 年 10 月
BookCorpus	书籍	5GB	University of Toronto & MIT	2015 年 12 月
Project Gutenberg	书籍	-	University of North Carolina	2021 年 12 月
arXiv dataset	论文	1.1TB	Cornell University	2019 年 04 月
S2ORC	论文	-	Allen Institute for AI	2023 年 01 月
peS2o	论文	-	Allen Institute for AI	2023 年 06 月
BigQuery	代码	-	Google	-
The Stack	代码	6.4TB	BigCode	2022 年 11 月
StarCoder	代码	783GB	BigCode	2023 年 05 月
The Pile	混合	800GB	EleutherAI	2020 年 12 月
ROOTS	混合	1.6TB	BigScience	2022 年 06 月
Dolma	混合	6TB	Allen Institute for AI	2024 年 01 月

• *Common Crawl*. 该数据集是一个规模庞大的、非结构化的、多语言的网页数据集，其时间跨度很长，从 2008 年至今一直在定期更新，包含原始网页数据、元数据和提取的文本数据等，总数据量达到 PB 级别。由于这个数据集规模过于庞大，现有的研究工作主要提取其特定时间段或者符合特殊要求的子集进行使用，后文也将介绍多个基于 Common Crawl 的网页数据集。值得注意的是，该数据集内部充斥着大量的噪声和低质量数据，在使用前必须进行有效的数据清洗，以确保数据质量和准确性，常用的自动清洗工具有 CCNet 等。

• *C4* (Colossal Clean Crawled Corpus) [77]. 该数据集是一个大型网页数据集，源自超过 365M 个互联网域，包含超过 156B 词元，数据量约 800GB。该数据集基于 2019 年 4 月的 Common Crawl 语料构建，已经被公开发布²，使用该数据集的典型模型有 UL2 和 LLaMA。此外，该数据集针对不同需求，发布了多个子版本：

²<https://www.tensorflow.org/datasets/catalog/c4>

en (英文数据, 806G), en.noclean (未清洗的原始数据, 6T), realnewslike (仅包含 RealNews 涉及的领域的内容, 36G), webtextlike (仅包含来自 OpenWebText 中 URLs 的内容, 17G) 和 multilingual (多语言数据, 38T)。

- *CC-Stories*. 该数据集是一个专为常识推理和语言建模构建的故事风格数据集, 数据来源是 Common Crawl 中与常识推理任务问题有高度重叠的文档, 总共包含约 5.3B 个词元, 数据量约 31GB。CC-Stories 的原始来源现在无法访问, 只有复现版本 *CC-Stories-R* [78] 可供使用。使用该数据集训练的代表性模型包括 Megatron-Turing NLG 等。

- *CC-News* [79]. 该数据集是一个新闻文章数据集, 数据量约 76GB, 包含了从 2016 年 9 月到 2019 年 2 月期间抓取的 63M 篇英文新闻文章, 并以网页存档 (WARC) 文件形式提供, 在 Hugging Face 上可以进行下载。

- *REALNEWS* [80]. 该数据集是一个从 Common Crawl 中抓取的大型新闻语料库, 覆盖了谷歌新闻索引的 5,000 个新闻领域, 数据量约为 120GB, 可从 OpenDataLab 上进行下载。该数据集按照时间顺序进行了训练集和测试集的划分, 其中 2016 年 12 月至 2019 年 3 月的新闻划分为训练数据, 2019 年 4 月的新闻划分为测试数据。

- *RedPajama-Data* [81]. 该数据集是一个公开的综合网页数据集, 包含了来自 Common Crawl 的 100B 份文档, 其使用了 CCNet 工具进行清洗, 在经过过滤和去重得到约 30T 词元, 在 Hugging Face 上提供了公开下载。该数据集是一个多语言数据集, 包含 5 种语言: 英语、法语、西班牙语、德语和意大利语。此外, 还提供了 40 余种预先标注好的数据注释, 使下游模型开发者能够根据自己的标准对数据集进行筛选或重新加权。该数据集仍在不断更新维护, 所有的数据处理脚本均在 GitHub 开源, 方便用户使用。

- *RefinedWeb* [82]. 该数据集是一个在 Common Crawl 数据的基础上通过严格筛选和去重得到的网络数据集, 使用的源数据是从 2008 年到 2023 年 6 月的所有 Common Crawl 网页记录, 共约 5T 词元。其中, 开源部分有 600B 词元, 数据量约 500GB, 解压后需要 2.8TB 的本地存储空间, 可从 Hugging Face 上下载。该数据集是开源大语言模型 Falcon 的主要训练数据集。

- *WanJuan-CC* (万卷 CC) [83]. 该数据集是一个从 Common Crawl 数据中抽取并清洗的高质量英文数据集。首批开源的语料覆盖了过去十年内互联网上的公开内容, 包含 100B 词元, 构成约 400GB 的高质量数据。在数据清洗过程中, 发

布人员搭建了高性能分布式数据处理系统，通过启发式规则过滤、多层级数据去重、内容安全过滤、数据质量过滤等四个步骤，最终从约 130B 份原始数据文档中萃取出约 1.38% 的高质量内容。上海人工智能实验室发布的 InternLM2 [84] 就是以 WanJuan-CC 作为关键数据进行训练。

- *WebText*. 该数据集是由 OpenAI 构建的一个专注于文档质量的网络文本语料库，它通过抓取 Reddit 上获得至少 3 个赞的外链得到。该语料库旨在捕捉用户认为有趣、有教育价值或幽默的内容，使用的数据是 2017 年 12 月之前的数据，包括了来自 45M 个链接的文本内容，共计超过 8M 份文档，文本总量达到 40GB。OpenAI 在一系列模型的训练过程中，都是使用了该数据集，包括 GPT-2、GPT-3 和 InstructGPT 等。遗憾的是，WebText 并未开源。

- *OpenWebText*. 该数据集是 WebText 的一个复现开源版本，与 WebText 的构建方法相似，其首先从 Reddit 上提取网页链接，经过去重、过滤等处理，最终保留了来自约 8M 份文档的 38GB 文本数据。该数据集可在 Hugging Face 上进行下载。

中文网页数据

在上述网页数据集中，中文网页占比通常非常低。为了训练具有较好中文语言能力的大语言模型，通常需要专门收集与构建中文网页数据集合。下面介绍具有代表性的中文网页数据集。

- *ChineseWebText* [85]. 该数据集是从 Common Crawl 庞大的网页数据中精心筛选的中文数据集。该数据集汇集了 2021 年至 2023 年间的网页快照，总计 1.42TB 数据量。同时，ChineseWebText 的每篇文本都附有一个定量的质量评分，为研究人员提供了可用于筛选与使用的参考标准。此外，为满足不同研究场景的需求，ChineseWebText 还特别发布了一个 600GB 大小的中文数据子集，并配套推出了一款名为 EvalWeb 的数据清洗工具，方便研究人员根据需求清洗数据。

- *WanJuan 1.0 Text* [86]. 该数据集是上海人工智能实验室发布的万卷 1.0 多模态语料库的一部分（除文本数据集外，还有图文数据集和视频数据集）。该文本数据集由多种不同来源的数据组成，包括网页、书籍等，数据总量约 500M 个文档，数据大小超过 1 TB。在数据处理过程中，该语料将多种格式的数据进行了统一，并进行了细粒度的清洗、去重，提升了语料的纯净度。该数据集被用于 Intern Multimodal 和 Intern Puyu 的训练，完整数据集可在 Opendatalab 上进行下载。

- *WuDaoCorpora Text* [87]. 该数据集是北京智源研究院构建的“悟道”项目数据集的一部分（除文本数据集外，还有多模态图文数据集和中文对话数据集）。该文

本数据集来源于 100TB 高质量原始网页数据，其中还包含教育、科技等超过 50 个行业数据标签，经过清洗、隐私数据信息去除后剩余 5TB，而开源部分有 200GB。

- *SkyPile-150B* [88]. 该数据集是一个大规模的综合中文数据集，数据来源于公开可获取的中文网页，其公开部分包含大约 233M 个网页，总共包含约 150B 个词元，620GB 的纯文本内容。为了确保数据质量，该数据集进行了严格的过滤、去重以及隐私数据的清除。此外，还使用了 fastText 等工具进一步筛除低质量数据。该数据集被用于训练 Skywork 模型。

3.2.2 书籍

书籍是人类知识与文化的重要载体，已经成为了重要的预训练数据源之一。书籍内容主要是长文本形式表达，能够帮助语言模型学习语言的长程依赖关系，并深入理解语言的内在逻辑与表达习惯。通常来说，书籍的语言表达更为严谨，整体上相对质量较高，并且能够覆盖多元化的知识体系。需要注意的是，书籍通常都是有着较为严格的版权限制，使用者需要按照版权的要求来判断是否能够使用某一书籍用于训练。目前，常用的书籍数据集包括下述几个数据集合。

- *BookCorpus* [89]. 该数据集是一个免费小说书籍集合，包含了 11,038 本未出版书籍（大约有 74M 句子和 1B 个单词），涵盖了 16 种不同的主题类型（如浪漫、历史、冒险等），本地存储大概需要 5GB 左右。该数据集常被用于训练小规模模型，如 GPT [14] 和 GPT-2 [17]。同时，BooksCorpus 也被 MT-NLG [90] 和 LLaMA [34] 等模型所使用。该数据集原始数据集不再公开，但多伦多大学创建了一个镜像版本 BookCorpusOpen，可在 Hugging Face 上进行下载，该版本包含了共计 17,868 本书籍，本地存储大概需要 9GB 左右。至于在 GPT-3 [23] 中使用的 Books1 [23] 和 Books2 [23] 数据集合，比 BookCorpus 规模更大，但目前也尚未对外公开。

- *Project Gutenberg*. 这是一个拥有 70K 部免费电子书的在线图书馆，目前还在持续更新中。主要收录了西方文学作品，包括小说、诗歌、戏剧等，大部分作品以纯文本形式提供，也有一些非文本内容例如音频和乐谱。收录中大部分作品为英语，也涵盖了法语、德语等多种语言，用户可以在其官方网站免费下载需要的电子书³。

- *arXiv Dataset*. arXiv 是一个收录了众多领域预印本论文的网站。为了更好地方便研究工作的使用，arXiv 官方在其网站上发布了一个机器可读的 arXiv 论文

³<https://www.gutenberg.org/ebooks/>

数据集 [91], 广泛涵盖了物理、数学和计算机科学等领域的论文文献, 共包含约 1.7M 篇预印本文章, 每篇预印本都包含文本、图表、作者、引文、分类以及其他元数据等信息, 总数据量约为 1.1TB, 并在 Kaggle 上提供了公开下载。

• **S2ORC [92]**. 该数据集源于学术搜索引擎 Semantic Scholar 上的学术论文, 这些论文经过了清洗、过滤并被处理成适合预训练的格式。S2ORC 到目前为止已发布多个版本, 最初的版本包含 81M 篇公开论文, 目前已更新至 136M 篇。该数据集已在 Semantic Scholar 上提供了可公开下载的版本。此外, 该数据集还有一个衍生数据集 peS2o [93], 到目前为止已发布了两个版本, 其中 v2 版本共计包含了约 42B 词元, 并且在 Hugging Face 提供了公开下载。

3.2.3 维基百科

维基百科 (Wikipedia) 是一个综合性的在线百科全书, 由全球志愿者共同编写和维护, 提供了高质量的知识信息文章, 涵盖了历史、科学、文化艺术等多个领域。维基百科的数据具有以下几个特点: (1) 专业性: 维基百科的条目通常具有良好的结构性和权威性, 不仅对于各种专业术语和概念进行了阐释, 还揭示了它们在不同领域的应用和联系; (2) 多语性: 维基百科支持的语言种类繁多, 有汉语、英语、法语、德语等一共 300 多种语言, 是一个宝贵的多语言平行语料库; (3) 实时性: 维基百科的内容目前还在不断更新, 对于知识信息的实时性维护较为及时, 并且会定期发布其数据库的打包副本, 供研究人员获取最新数据。除了通过维基百科的官方提供的下载方式⁴, Hugging Face 上也有相应的维基百科数据集⁵。在实际应用中, 可以根据需求选择特定时间段或特定内容的数据。例如 LLaMA 使用的是 2022 年 6 月至 8 月的维基百科数据。

3.2.4 代码

代码是计算机程序设计和软件开发的基础, 具有高度结构化与专业性的特点。对于预训练语言模型来说, 引入包含代码的数据集可以增强模型的结构化推理能力与长程逻辑关系, 能够提升模型理解和生成编程语言的能力。为了收集代码数据, 现有的工作主要从互联网上爬取具有开源许可的代码。两个主要来源是公共

⁴<https://dumps.wikimedia.org/>

⁵<https://huggingface.co/datasets/wikipedia>

代码仓库（例如 GitHub）和代码相关的问答平台（例如 StackOverflow）。下面是几个常用于预训练的代码数据集。

- *BigQuery*. BigQuery 是一个谷歌发布的企业数据仓库，包含了众多领域的公共数据集，如社交、经济、医疗、代码等。其中的代码类数据覆盖各种编程语言，可以作为高质量的代码预训练语料。CodeGen 抽取了 BigQuery 数据库中的公开代码数据子集构成 BIGQUERY [94] 进行训练，以得到多语言版本的 CodeGen。

- *The Stack* [95]. 该数据集由 Hugging Face 收集并发布，是一个涵盖了 30 种编程语言的代码数据集，其数据来源于 GHArchive 项目中 2015 年 1 月 1 日至 2022 年 3 月 31 日期间的 GitHub 活跃仓库。The Stack 最初的版本经过数据筛选、过滤以及许可证检测等处理后，最终数据量约为 3TB。同时，该数据集还在不断更新中，v1.2 版本的编程语言已扩展到了 358 种，并且许可证列表也得到了扩充，以收集更多数据，目前该版本数据量约为 6TB，可以在 Hugging Face 上进行下载。

- *StarCoder* [96]. 该数据集是 BigCode 围绕 The Stack v1.2 进一步处理得到的代码数据集，是同名模型 StarCoder 的预训练数据。在数据处理上，其根据数据量、流行度排名等因素，从 The Stack v1.2 的 358 种编程语言中筛选出了 86 种语言，同时，为了确保数据质量，该项目还对数据进行了人工抽样审核，以确认数据为人类编写的正常代码，而不是文本或自动生成的代码。此外，数据处理过程还进行了对多种文件类型的过滤，以去除低质量数据。最终数据总量约为 783GB，同样可以通过 Hugging Face 进行下载。

3.2.5 混合型数据集

除了上述特定类型的数据集外，为了便于研发人员的使用，很多研究机构对于多种来源的数据集合进行了混合，发布了一系列包括多来源的文本数据集合。这些混合数据集往往融合了新闻、社交媒体内容、维基百科条目等各种类型的文本，减少了重复清洗数据、选择数据的繁重工程。下面介绍几个具有代表性的混合数据集。

- *The Pile* [97]. 该数据集是一个大规模、多样化且可公开下载的文本数据集，由超过 800GB 的数据组成，数据来源非常广泛，包括书籍、网站、代码、科学论文和社交媒体数据等。该数据集由 22 个多样化的高质量子集混合而成，包括上面提到的 OpenWebText、维基百科等，并在混合时根据数据集质量为其设定不同的权重，以增大高质量数据集的影响，最终总数据量约为 825GB。The Pile 数据集在不同

参数规模的模型中都得到了广泛应用。例如，GPT-J (6B) [98]、CodeGen (16B) [94] 以及 Megatron-Turing NLG (530B) [90]。

- **ROOTS** [99]. 该数据集是一个涵盖了 59 种不同语言的多源多语数据集。该数据集主要由两部分组成：约 62% 的数据来源于整理好的自然语言处理数据集及相关文档、利用 Common Crawl 收集的网页数据以及 GitHub 代码数据，约 38% 的数据来源于一个网页爬虫项目 OSCAR，并对其进行了内容过滤、去重和个人信息移除。ROOTS 数据集包含了 46 种自然语言，其中英语占比最大，约为 30%；同时包含了 13 种编程语言，其中 Java、PHP 和 C++ 占比超过一半，总数据量约为 1.6TB，可以从 Hugging Face 上进行下载。该数据集用于训练 BigScience Workshop 提出的 BLOOM 模型 [100]。

- **Dolma** [101]. 该数据集也包含了多种数据源，包括来自 Common Crawl 的网络文本、Semantic Scholar 学术论文、GitHub 代码、书籍、Reddit 的社交媒体帖子以及维基百科数据，由来自大约 200TB 原始文本的 3T 个词元组成。在 Dolma 的处理过程中，发布团队同时创建了一个高性能工具包，实现了四种常用的数据清洗和过滤方法：语言过滤、质量过滤、内容过滤以及去重。同时，Dolma 仍在不断更新中，目前 v1.6 的版本文件大小约为 5.4TB，可以在 Hugging Face 上进行下载。AI2 研究院基于 Dolma 数据集训练并发布了 OLMo [102]，这是一个提供了完整的训练数据、代码、模型参数等资源的大语言模型。

3.3 常用微调数据集

为了增强模型的任务解决能力，大语言模型在预训练之后需要进行适应性微调，通常涉及两个主要步骤，即指令微调（有监督微调）和对齐微调。本节将主要讨论可用于微调的数据集，关于大模型微调的更多算法细节详见第 7 章和第 8 章。

3.3.1 指令微调数据集

在预训练之后，指令微调（也称为有监督微调）是增强或激活大语言模型特定能力的重要方法之一（例如指令遵循能力）。本小节将介绍几个常用的指令微调数据集，并根据格式化指令实例的构建方法将它们分为三种主要类型，即自然语言处理任务数据集、日常对话数据集和合成数据集。表 3.3 中展示了它们的详细信息，更详细的构建方式见第 7.1 节。

表 3.3 指令微调的数据集

类别	集合	时间	# 样本数量	来源
任务	Nat. Inst.	2021 年 04 月	193K	Allen Institute for AI
	FLAN	2021 年 09 月	4.4M	Google
	P3	2021 年 10 月	12.1M	BigScience
	Super Nat. Inst.	2022 年 04 月	5M	Allen Institute for AI
	MVPCorpus	2022 年 06 月	41M	Renmin University of China
	xP3	2022 年 11 月	81M	BigScience
	OIG	2023 年 03 月	43M	LAION-AI
	UnifedSKG	2022 年 03 月	812K	The University of Hong Kong
对话	HH-RLHF	2022 年 04 月	160K	Anthropic
	HC3	2023 年 01 月	87K	SimpleAI
	ShareGPT	2023 年 03 月	90K	TechCrunch
	Dolly	2023 年 04 月	15K	Databricks
	OpenAssistant	2023 年 04 月	161K	LAION-AI
	InstructWild v2	2023 年 04 月	111K	National University of Singapore
	LIMA	2023 年 06 月	1K	Meta AI
合成	Self-Instruct	2022 年 12 月	82K	University of Washington
	Alpaca	2023 年 03 月	52K	Stanford
	Guanaco	2023 年 03 月	535K	-
	Baize	2023 年 04 月	158K	University of California, San Diego
	Belle	2023 年 04 月	1.5M	LianjiaTech
	Alpaca-GPT4	2023 年 04 月	52K	Microsoft
	Evol-Instruct	2023 年 06 月	52K	Microsoft
	UltraChat	2023 年 06 月	675K	Tsinghua University

自然语言处理任务数据集

在指令微调被提出前，早期的研究通过收集不同自然语言处理任务（如文本分类和摘要等）的实例，创建了有监督的多任务训练数据集。这些多任务训练数据集成为了构建指令微调数据集的重要来源之一。一般的方法是使用人工编写的任务描述来扩充原始的多任务训练数据集，从而得到可以用于指令微调的自然语言处理任务数据集。其中，P3 [40] 和 FLAN [39, 103] 是两个代表性的基于自然语言处理任务的指令微调数据集。

- **P3**. P3 (Public Pool of Prompts) 是一个面向英文数据的指令微调数据集，由超过 270 个自然语言处理任务数据集和 2,000 多种提示整合而成（每个任务可能不止一种提示），全面涵盖多选问答、提取式问答、闭卷问答、情感分类、文本摘要、主题分类、自然语言推断等自然语言处理任务。P3 是通过 Promptsources (一个收集任务提示的众包平台) 收集的，其子集被用来训练 T0 模型 [40]。

- **FLAN**. 早期的 FLAN 是通过将 62 个广泛使用的 NLP 基准数据集进行格式

化得到的英语指令数据集。现在俗称的 FLAN 实际上是指 FLAN-v2，主要由四个子集 Muffin、NIV2、T0-SF 和 CoT 构成。其中，Muffin 由之前 FLAN 的 62 个任务和新加入的 26 个任务组成（包括对话数据和代码合成数据）；T0-SF 则是从 T0 模型 [40] 的数据中抽取出来，同时确保与 Muffin 不重叠；NIV2 指的是数据集 Natural-Instructions v2；而 CoT 则是为了增强模型的推理能力而加入的九种不同推理任务的组合。与此同时，FLAN-v2 对每项任务都设置了最大上限，因为在同一混合数据集中，有些任务比其他任务大得多，这可能会在采样中占主导地位，从而影响模型的训练效果。据 FLAN 论文，使用了 Muffin: 52%，T0-SF: 15%，CoT: 3%，NIV2: 30% 这一混合比例，通常能够使得模型具有较好表现。

日常对话数据集

日常对话数据集是基于真实用户对话构建的，其中查询主要是由真实用户提出的，而回复是由人类标注员回答或者语言模型所生成。主要的对话类型包括开放式生成、问答、头脑风暴和聊天。其中，三个较为常用的日常对话数据集包括 ShareGPT [38]、OpenAssistant [104] 和 Dolly [105]。

- *ShareGPT*. 该数据集因来源于一个开源的数据收集平台 ShareGPT 而得名。在该平台中，用户可以将自己的各种对话数据通过浏览器插件进行上传。这些对话包括来自 OpenAI ChatGPT 的用户提示和回复，语种主要为英语和其他西方语言。具体来说，查询来自于用户的真实提问或指令，回复则是 ChatGPT 对此生成的回答。

- *OpenAssistant*. 该数据集是一个人工创建的多语言对话语料库，共有 91,829 条用户提示，69,614 条助手回复。OpenAssistant 共包含 35 种语言的语料，每条语料基本都附有人工标注的质量评级（例如回复的有用性、无害性等）。值得注意的是，这里所有的数据都是由用户真实提供的，与上面所提到 ShareGPT 的数据构建方式并不相同。

- *Dolly*. 该数据集是一个英语指令数据集，由 Databricks 公司发布。Dolly 包含了 15,000 个人类生成的数据实例，旨在让大语言模型与用户进行更符合人类价值的高效交互。该数据集由 Databricks 员工标注得到，主题涉及 InstructGPT 论文中提到的 7 个领域，包括头脑风暴、分类、封闭式质量保证、生成、信息提取、开放式质量保证和总结等。

合成数据集

合成数据集通常是使用大语言模型基于预定义的规则或方法进行构建的。其

中，Self-Instruct-52K [74] 和 Alpaca-52K [42] 是两个具有代表性的合成数据集。

- *Self-Instruct-52K*. Self-Instruct-52K 是使用 self-instruct 方法（详见第 7.1.3 节）生成的英语指令数据集，共包含 52K 条指令以及 82K 个实例输入和输出。最初，由人工收集创建了 175 个种子任务，每个任务包括 1 个指令和 1 个包含输入输出的实例。然后，每次随机抽取了 8 个指令作为示例，以此提示 GPT-3 生成了新的指令，之后在这些已有指令的基础上，继续利用 GPT-3 生成实例输入及其对应的输出，从而获得了更多数据。这些新得到的指令和输入输出经过滤（去除低质量或重复数据）后会加入数据集中，并继续类似的循环。通过迭代上述过程，最终获得了 52K 条指令和 82K 个实例数据，其中每一条指令可能会用于生成多个输入输出的实例。

- *Alpaca-52K*. Alpaca-52K 数据集同样是基于 self-instruct 方法进行构建的，它是在 Self-Instruct-52K 的 175 个种子任务上，利用 OpenAI 的 text-davinci-003 模型获得了 52K 个不重复的指令，并根据指令和输入生成了输出，进而构成了完整的实例数据。与 Self-Instruct-52K 不同，这里每条指令仅对应于一个输入输出实例。此外，Alpaca-52K 在生成数据的过程中考虑到了输入的可选性，最终的数据中只有 40% 具有输入部分。也正是因此，Alpaca 也包含两种提示模板：包括输入以及不包括输入。

3.3.2 人类对齐数据集

除了指令微调之外，将大语言模型与人类价值观和偏好对齐也非常重要。现有的对齐目标一般聚焦于三个方面：有用性、诚实性和无害性，这三种对齐标准的具体定义可见第 8.1.2 节。本节将介绍几个代表性的对齐微调数据集，它们各自针对上述对齐目标进行了标注，包括 HH-RLHF [106]、SHP [107]、PKU-SafeRLHF [108]、Stack Exchange Preferences [109]、Sandbox Alignment Data [110] 和 CValues [110]。表 3.4 中展示了这些数据集的详细信息。

- *HH-RLHF*. 该数据集包含两大类标注数据，分别关注于大语言模型的有效性和无害性。整个数据集共包含约 169K 个开放式对话，每个对话涉及一个众包工作者向一个智能信息助手寻求帮助、建议或请求完成任务等情景。信息助手将会为每个用户查询提供两个回复，一个回复被选择而另一个被拒绝。对于有用性相关的数据中，被认为更有用的回复将被选择；而对于无害性相关的数据中，被认为更有害的回复则将被选择。

表 3.4 可用于人类对齐的数据集

数据集	时间	# 样本数量	来源	对齐目标
Summarize from Feedback	2020 年 09 月	193K	OpenAI	有用性
SHP	2021 年 10 月	385K	Standfordnlp	有用性
WebGPT Comparisons	2021 年 12 月	19K	OpenAI	有用性
Stack Exchange Preferences	2021 年 12 月	10M	HuggingFaceH4	有用性
HH-RLHF	2022 年 04 月	169K	Anthropic	有用性、无害性
Sandbox Alignment Data	2023 年 05 月	169K	Google	有用性、诚实性、无害性
CValues	2023 年 07 月	145K	Alibaba	无害性
PKU-SafeRLHF	2023 年 10 月	330K	PKU-Alignment	有用性、无害性

• *SHP*. 该数据集主要关注模型生成回复内容的有用性。该数据集共 385K 个数据实例，对于 18 个不同主题领域中问题/指令的人类偏好进行标注，涵盖了从烹饪到法律建议等各种主题。每个数据实例都是基于一个寻求帮助的 Reddit 帖子构建的，包含该帖子中的问题和帖子下两个排名较高的评论。这两个评论其中一个被 Reddit 用户认为更有用，另一个被认为不太有帮助。与 HH-RLHF [106] 不同，SHP 中的数据并非模型生成，而是人类的回复帖子。

• *PKU-SafeRLHF*. 该数据集侧重于对回复内容的有用性和无害性进行标注。该数据集囊括了 330K 个专家注释的实例，每一个实例都包含一个问题及其对应的两个回答。其中，每个回答都配备了安全性标签，用以明确指出该回答是否安全。此外，标注者还会就这两个回答在有用性和无害性方面进行细致的比较和偏好注释。

• *Stack Exchange Preferences*. 该数据集专注于对答案的有用性进行标注，涵盖了来自知名编程问答社区 Stack Overflow 的约 10M 个问题和答案，具有很高的实用价值。每个数据实例均包含一个具体的问题以及两个或更多的候选答案。每个候选答案都附有一个根据投票数计算得出的分数，并附带了一个表示是否被选中的标签。

• *Sandbox Alignment Data*. 该数据集致力于运用模型自身的反馈机制来进行数据标注，而非依赖人类的直接参与。此数据集源自于一个名为 SANDBOX 的虚拟交互环境，该环境模拟了人类社交互动的场景。在这个环境中，多个大语言模型根据问题给出回复然后互相“交流”，并根据彼此的反馈来不断修正和完善自己的回复，以期达到更佳的交互效果。该数据集涵盖了 169K 个实例，每个实例均包含一个查询、多个回复选项以及由其他模型给出的相应评分。

• *CValues*. 该数据集是一个面向中文的大模型对齐数据集，提出了安全性和

责任性这两个评估标准。这个数据集包含了两种类型的提示：安全性提示和责任性提示。安全性提示共有 1,300 个，主要用于测试模型的安全性表现，这些提示的回复被人工标注为安全或不安全，但由于内容敏感，因此并未开源；责任性提示共有 800 个，这些提示由领域专家提供，并用于评估模型在特定领域内的责任性表现，专家也为这些提示的回复进行了打分。由于内容敏感，实际开放的数量有删减。除此之外，CValues 还提供对比形式的数据集，该数据集中一共有 145K 样例，每条样例包含提示、正例回复（被认为更安全更负责任的回复）和负例回复，这部分数据被完全开源。

3.4 代码库资源

除了数据资源外，各大研究机构还在不断推动大语言模型相关代码库的建设与开源。本节将介绍一些用于开发大语言模型的代表性代码库。

3.4.1 Hugging Face 开源社区

Hugging Face 是一个致力于推动自然语言处理技术进步的开源社区，专注于为研究人员和工程师提供高效、易用且可重复的自然语言处理技术解决方案。这些解决方案既包括基础的技术流程，如预训练和微调，也涉及具体的应用任务，包括对话系统、翻译等。Hugging Face 平台上的代码大部分基于目前主流的深度学习框架实现完成的，如 PyTorch 和 TensorFlow。为了满足广泛的研究与应用需求，Hugging Face 发布了一系列代码库，包括 Transformers、Datasets 和 Accelerate 等。

- *Transformers*. 该代码库是一个使用 Transformer 架构构建模型的开源 Python 库，提供了一系列预训练的模型与相关开发工具，在自然语言处理领域被广泛使用。Transformers 库的主要优势包括如下四点。（1）易于使用：对所有模型的 API 进行了统一封装，研究者只需了解三个核心类（模型、配置和分词器），即可快速上手。（2）节省资源：鼓励模型开源共享，减少重复训练，节约计算资源。（3）广泛支持：提供数以万计的预训练模型，满足多样化需求。（4）全周期管理：简化模型训练到部署的过程，支持跨框架模型转换，易于设计模型和构建实验。

- *Datasets*. 该代码库用于高效访问和共享自然语言处理任务相关的数据集，可以快速从远程 Hugging Face Hub 中加载数据集到本地。在使用中，用户仅需一行代码便能加载指定的数据集，同时，该库还集成了强大的数据处理能力，以满足各

种复杂的数据操作需求。得益于软件框架 Apache Arrow 格式的支持，Datasets 能够实现大型数据集的零拷贝读取，从而减少内存占用，显著提升数据处理的效率。

- *Accelerate*. 该代码库是一个旨在简化模型分布式训练和混合精度训练的 Python 库，专门针对 PyTorch 开发。Accelerate 库全面支持分布式训练，实现了混合精度训练，并完善了并行训练时多设备的自动管理。该库降低了用户进行分布式训练的难度，仅通过少量代码，用户便能在各种分布式配置中执行 PyTorch 程序，从而便捷地使用大规模计算资源，有效加快模型训练的进度。此外，Accelerate 还提供了一个可配置的命令行界面工具，进一步简化了训练环境的配置与测试流程。

3.4.2 DeepSpeed

DeepSpeed 是微软开发的一个加速深度学习模型训练的高性能库（与 PyTorch 兼容），被广泛用于大语言模型的分布式训练，例如 MT-NLG [90] 和 BLOOM [100] 等。DeepSpeed 为分布式训练提供了各种优化技术支持，如内存优化（ZeRO 技术、梯度检查点）、数据并行、混合精度训练等，使得整个训练过程变得更加高效、稳定。为了更加适配大模型时代的用户需求，DeepSpeed 针对模型生成和强化学习分别开发了特制的优化框架：DeepSpeed-MII 和 DeepSpeed-Chat。下面针对这两个优化框架进行介绍。

- *DeepSpeed-MII*. 该框架旨在通过提高吞吐量、降低延迟等方式来降低大模型解码生成的运行成本。首先，DeepSpeed-MII 实现了两项重要技术以加速文本生成过程：（1）块状键值缓存，将键值缓存分割成固定大小的块，从而减少了内存碎片化的情况，提升整体的系统吞吐量；（2）连续批处理，在模型的每个前向传播过程中进行独立的调度决策，以实现更细粒度的调度和优化内存效率。在此基础上，DeepSpeed-MII 又提出了 SplitFuse 技术，将提示和生成结果进行动态分解，以进一步改善连续批处理和系统吞吐量。它目前已支持包括 LLaMA、Mistral、Falcon、Mixtral 和 Qwen 在内的多个模型。

- *DeepSpeed-Chat*. 该框架是一个易于使用的用于训练类 ChatGPT 模型的开发工具，完整集成了包括基于人类反馈的强化学习算法在内的训练过程。它具有三个主要功能：（1）使用方便快捷。该框架简化了类 ChatGPT 模型的训练和生成过程，使得用户可以用简单的脚本实现多个训练步骤，并且提供了用于测试对话式交互的 API；（2）训练通路完整。该框架复现了 InstructGPT [28] 的训练过程，包

括有监督微调、奖励模型训练和基于人类反馈的强化学习，还提供了数据抽象和混合功能，以帮助用户运行完整的训练流程；(3) 将 DeepSpeed 的训练和生成集成到了一个统一框架中，实现了在 RLHF 中训练和生成模式之间的无缝切换，使其可以利用 DeepSpeed 的各种优化技术。

3.4.3 Megatron-LM

Megatron-LM [27, 111, 112] 是由 NVIDIA 开发的一款专门为训练大语言模型而设计的深度学习代码库。这个代码库旨在解决大型模型训练过程中所遇到的一系列技术挑战，包括显存限制、计算效率以及不同的并行策略带来的通信问题。Megatron-LM 引入了一系列分布式训练的优化技巧，支持多种并行化策略，包括 (1) 数据并行，通过在每个工作节点复制模型，并将输入数据切分多份分配给多个节点，定期同步所有梯度来提升 GPU 的使用效率；(2) 模型并行，包括张量并行和流水线并行，通过在多个工作节点上分配模型和计算来克服单个 GPU 容量限制的问题。此外，Megatron-LM 还支持混合精度训练和 FlashAttention 功能。这些优化技术可以在很大程度上提高训练效率和速度，实现跨 GPU 的高效分布式训练。关于并行训练的内容可以进一步参阅第 6.3.1 节的相关介绍。

3.4.4 本书配套资源说明

为了更好地配合本书的完成，作者团队还提供了非常丰富的配套资源，用于辅助本书的阅读与学习。

- *LLMSurvey* [10]. 2023 年 3 月末，笔者团队在预印版网站 arXiv 上发表了大语言模型英文综述论文《A Survey of Large Language Models》，全面介绍了大语言模型的主要技术路径与最新研究进展。该综述论文目前已迭代至 v13 版本，全文长达 123 页，收录了 946 篇参考文献，内容全面涵盖了大模型相关资源、预训练、指令微调、人类对齐、提示学习以及评测等多方面的技术介绍。同时建立了大模型综述资源网站：<https://github.com/RUCAIBox/LLMSurvey/>，收录了很多相关论文与学习资源。自该综述文章推出以来，受到了广泛的关注。本书在此英文综述文章的基础上拓展而来，但是具有不同的定位目标：英文综述文章主要是面向学术前沿，力争覆盖目前最新的研究进展；本书则主要面向辅助教学，旨在形成一本大语言模型的入门级中文教材。

- *YuLan-Chat* [73]. YuLan-Chat 是中国人民大学自主研发的系列大语言模型，

目前已研发至第三代版本，即 YuLan-Chat-3。YuLan-Chat-3 经历了完整的从头预训练、指令微调以及人类对齐的训练过程，包含 12B 的参数规模，预训练数据量达到 1.68T 词元。我们同时在 GitHub 上开源了三代 YuLan 的权重参数，以供读者进行尝试使用。本书所介绍的很多相关技术，均是作者团队在研发 YuLan-Chat 系列模型过程中进行实践与思考所凝练。为了介绍方便，在后续章节中，将简称 YuLan-Chat-3 为 *YuLan* 模型。

- **LLMBox**⁶. LLMBox 是作者团队围绕英文综述论文所开发的综合性大语言模型代码库，用于支持大模型训练与评测的学术研究工作。其中，训练部分涵盖了大语言模型的预训练、指令微调、对齐微调以及轻量化微调等多种训练策略，并为读者提供了 GPU 计算器来估算训练时所需的显存开销；评测部分支持了大量开源模型和商用 API 在多种下游任务上的评测，还设计了前缀缓存机制提升使用效率。LLMBox 在开发过程中，力求使用尽可能简短的代码展现相关技术的实现或调用，并提供了“一键运行”脚本，让读者能够更为容易地尝试大模型的各种训练与评测技术。

为了向读者提供一个更为直观的理解途径，本书在后续的章节中，将在代码实践中结合 YuLan 模型、LLMBox 以及其他相关自研软件（如数据清洗软件库 YuLan-GARDEN [113]、智能体仿真软件库 RecAgent [114] 等）进行具体技术的讲解。这些示例不仅紧密贴合了书中所介绍的理论知识，而且通过具体的实践操作步骤展示，将帮助读者更好地掌握如何在实际工作中运用大语言模型相关技术。

⁶<https://github.com/RUCAIBox/LLMBox>