

第十三章 应用

作为一条新技术路径，大语言模型对于人工智能算法的研究与实践产生了重要的影响。在本章节中，我们将分别介绍大语言模型在研究领域和专业领域中的应用进展情况。

13.1 大语言模型在研究领域的应用

在本节中，我们将围绕几个具有代表性的研究领域展开讨论，探究大语言模型在这些领域内所带来的影响。

13.1.1 传统自然语言处理任务中的大语言模型

语言模型是自然语言处理领域的重要研究方向之一，相关技术进展有力地推动了下游应用任务的性能提升。本部分内容将主要介绍大语言模型在三大类经典自然语言处理任务上的应用，包括序列标注、关系抽取以及文本生成任务，这些任务构成了许多现有自然语言处理系统和应用的基础，图 13.1 展示了具体样例。

序列标注

序列标注任务，如命名实体识别（NER）和词性标注（POS），是一种基础的自然语言处理任务。通常来说，这类任务要求为输入文本序列中的每一个词项分配适当的语义类别标签，例如 NER 任务中经典的 B-I-O 标记方案（*Beginning*, *Inside* 和 *Outside*）。在深度学习时代，一种主流的技术方法是通过神经网络模型（如 CNN、LSTM 或 BERT 等）对于序列单元进行编码，然后再将编码后的序列作为特征输入到经典的条件随机场模型（CRF）中，进而 CRF 能够基于编码后的序列特征进行序列标签的结构化预测。不同于传统方法，大语言模型可以通过上下文学习或基于特殊提示的方式解决序列标注任务，而无须使用 B-I-O 标记。例如，仅需要给予大模型相关的提示（如“请识别出句子中包含的实体”）或任务示例（如“输入文本‘中华人民共和国今天成立了’，请抽取出其所包含的命名实体：‘中华人民共和国’”）即可自动抽取出实体。然而，大语言模型在传统序列标注任务上也面临着许多挑战 [404]，特别是在识别具有罕见或歧义名称的特殊实体时。原因在于大语言模型可能会误解特殊实体的含义，将其与常见的非实体词混淆，从而难以

根据上下文中的提示和示例准确将它们识别出来。

关系抽取

关系抽取任务关注于从非结构化文本数据中自动提取出蕴含的语义关系。例如，当输入为“莱昂内尔·梅西出生在阿根廷”，其包含的语义关系三元组为“莱昂内尔·梅西-出生地-阿根廷”。通常来说，这类任务会被转化为文本分类或序列标注任务，并可以采用对应的技术方法进行解决。由于大模型具有出色的推理能力，它能够借助特定提示方法（如上下文学习等）来完成关系抽取任务，并在涉及复杂推理场景的任务中相较于小模型更具优势。然而，当关系标签规模较为庞大时，这些知识信息难以完全通过上下文学习的方式注入到大语言模型中，可能会出现关系抽取效果较差的情况。因此，为了提高对各种场景的适应能力，可以使用大语言模型和小型模型互相配合的方法 [405]。例如，利用小模型进行候选关系的初筛，再利用大模型进一步从初筛后的候选关系中推理出最合适关系；也可以采用大语言模型对于数据进行初步标注，从而丰富可用于训练的小模型的标注数据。这种基于两种模型结合的工作范式在信息抽取场景下具有较好的应用场景。

文本生成

文本生成，如机器翻译和自动摘要，是在现实应用中常见的自然语言处理任务。目前，基于微调的小型语言模型已经被广泛部署于许多产品和系统中。由前述内容所述，大语言模型具备强大的文本生成能力，通过适当的提示方法，在很多生成任务中能够展现出接近人类的表现。此外，大语言模型的使用方式更为灵活，可以应对实际应用场景的很多特殊要求。例如，在翻译过程中，大语言模型能够与用户形成交互，进一步提高生成质量。然而，大语言模型难以有效处理低资源语言或领域下的文本生成任务，例如马拉地语到英语的翻译 [406]。这是因为预训练数据中缺乏低资源语言的数据语料，使得大语言模型无法有效掌握这些语言的语义知识与语法逻辑。

总结

下面总结在经典自然语言处理任务中使用大语言模型的建议和未来方向。

- 应用建议. 大语言模型和传统小模型具有各自的优点：大语言模型可以为各种自然语言处理任务提供统一的解决方案，并能够在零样本和少样本场景下取得有竞争力的表现；而小模型能够部署在资源受限的条件下，可以根据目标任务进行特定的训练或调整，在有充足高质量标注数据的情况下可以获得不错的性能表




图 13.1 大语言模型应用于传统自然语言处理任务

现。在应用中, 可以根据实际情况进行选择, 综合考虑标注数据可用性、计算效率、部署成本等多方面因素。

• 未来方向. 尽管大语言模型具有出色的通用能力, 但仍然无法有效应对低资源领域的自然语言处理任务, 如小语种翻译。为了更好地解决这些任务, 需要设计有效的方法 (如微调或提示技术等), 将所需要的任务信息或领域特定知识注入到大语言模型。在实践中, 将大小模型进行融合, 从而实现优势互补, 也是一个有前景的技术方向。此外, 在真实应用中, 用户的需求通常较为灵活多变, 很多任务的解决方案可能需要多次迭代, 大语言模型为此提供了一种高效的人机协作方式, 具有较好的应用前景 (如办公助手)。尽管语言模型主要源于传统自然语言处理任务, 但随着其相关技术的快速发展, 大语言模型已经能够解决更复杂、更高级的任务, 自然语言处理领域的研究范畴也不断被拓宽, 研究范式也受到了重要影响。

13.1.2 信息检索中的大语言模型

大语言模型对于传统信息检索技术与应用范式带来了重要影响。这两者在技术路径上具有紧密的互补性。大语言模型拥有强大的语言理解、推理与生成能力, 能够助力构建更为智能的信息检索系统; 而信息检索技术能够高效地从外界获取所需要的相关信息, 可以为大语言模型提供更为精确、可靠的上下文信息。本部分将概要介绍如何利用大语言模型提升信息检索效果, 以及检索增强的大语言模




图 13.2 信息检索中的大语言模型

型，图 13.2 展示了具体样例。

大语言模型提升信息检索任务

首先，针对第一个方面展开探讨，介绍大语言模型如何推动信息检索领域的技术发展，包括利用大语言模型进行信息检索和大语言模型增强的信息检索模型。

- 利用大语言模型进行信息检索. 现代信息检索系统通常采用检索-重排序的流水线框架 [407]。在这个框架内，检索模型首先从大规模语料库中检索相关的候选信息，然后由重排序模型对候选信息进行精细排序，以优化检索结果。利用大语言模型改进信息检索系统的研究工作主要可以分为两类。第一类方法将语言模型作为检索基座模型，其沿用以往稠密检索的训练方法，通过在检索数据上进行微调，构建检索器或重排序器，利用大语言模型较好的语义理解能力，提升文本表示的质量，进而提高检索效果。由于检索任务对于效率要求较高，研究人员一般使用规模相对较小的语言模型（如 Mistral-7B）用于稠密检索。第二类方法通过设计特殊的指令（例如“请判断下述查询和文档的相关程度”），直接引导大语言模型生成两者的相关程度（如相关度分类或者打分），用于对候选文档集合进行排序以完成检索任务 [408]。出于效率考虑，大多数研究工作主要将大语言模型应用

于重排序阶段，通常可以采用逐点评测法（Pointwise）、成对比较法（Pairwise）以及列表排序法（Listwise）三种方法对于召回的候选文档列表进行重排序。

- **大语言模型增强的信息检索模型.** 由于大语言模型具有出色的语义理解与生成能力，其可以为信息检索模型补充相关性信息。主要可以分为以下两类方法。第一类方法通过构造特殊的提示，使得大语言模型能够充当人类标注者的角色，以较低成本完成大规模训练数据的标注工作，为传统检索模型补充高质量标注数据。例如，针对检索语料库中的文档，可以引导大语言模型基于该文档生成一个候选查询，并将这组数据对扩充到训练数据中，实现训练数据增强。第二类方法同样通过设计特殊的提示，利用大语言模型对输入查询进行改写，辅助信息检索模型精准理解用户的需求。此外，还可以利用大语言模型对查询进行详细解释和扩充，并将这些内容附加到原始查询之后，帮助信息检索模型获取更全面的结果。

检索增强的大语言模型

受限于训练数据的时效性和局限性，当涉及实时新闻或特定专业领域内知识时，大语言模型的生成结果可能不够准确。为弥补这一不足，研究人员引入了检索增强生成（Retrieval-Augmented Generation, RAG）技术。该技术旨在通过信息检索系统从外部知识库中获取相关信息，为大语言模型提供时效性强、领域相关的外部知识，以减少大语言模型生成内容中的错误。然而，真实的应用场景下，检索返回的结果可能受限于检索质量、呈现格式、输入长度等问题，从而导致大语言模型不能很好地利用这些信息。为了使大语言模型在检索增强生成场景中有更好的表现，本节将介绍三种改进策略：输入优化，指令微调，和预训练策略。

- **输入优化策略.** 在检索增强生成的场景中，大语言模型主要面临两个主要挑战。首先，当处理包含多个参考文档的长文本时，其信息利用能力往往会下降；其次，检索到的结果中可能包含与任务无关的文档，这可能会干扰模型对关键信息的识别和处理。为了克服这些挑战，可以使用过滤、压缩、摘要等技术，在文档和词元两个层级优化模型输入。在文档层面，可以使用相关度排序模型度量文档与查询之间的相关程度，过滤与查询相关程度较低的候选文档。在词元层面，可以采用压缩或摘要方法来实现更细粒度的内容优化。具体来说，可以使用自动摘要模型对查询和检索文档生成综合性摘要，从中抽取更加精炼且与查询紧密相关的内容。由于这一过程可能会丢失重要的信息（例如人名中姓氏被删除），故可以预先对关键实体等重要信息进行抽取和保留，之后再对其进行恢复。

- **指令微调策略.** 指令微调策略可以用来加强大语言模型对于检索结果中所包

含信息的利用能力。该策略的核心在于构造面向检索文档利用的指令数据，并通过对大语言模型进行微调，提升其对文档信息的处理和理解能力。在指令设计时，需要关注两个问题。首先，需要确保模型能够平等地关注输入中不同位置（如开头、中间、结尾）的内容，以缓解某些位置的信息容易被忽略的问题（如中间位置）。其次，当存在不相关信息的检索文档时，大语言模型应尽可能地避免被这些信息干扰。基于这两点，可以通过添加特殊的指令数据，例如将相关文档放置于不同的位置，或包含不相关文档，以提升大语言模型在检索增强生成任务上的表现。

- **预训练策略.** 如果大语言模型最终主要用于信息检索任务，还可以在预训练阶段采用特殊的学习任务对其检索生成能力进行针对性的加强。一种常见的策略是将语料库中文档的标题或第一段文字作为查询，其余内容作为期望的生成结果，调用检索器依据查询获得相关文档。也有一些研究工作将每段话分为长度相等的两部分，其中前半部分作为查询，后半部分作为期望的生成结果。为了进一步强化大模型理解和利用相关文档的能力，还可以基于聚类方法构造相关文档集合，通过拼接关联文档以得到针对性的预训练数据 [272]。

总结

下面总结大语言模型与信息检索技术融合的应用建议与未来研究方向。

- **应用建议.** 信息检索技术和大语言模型可以互相促进。在提升信息检索系统方面，大语言模型凭借其强大的语义理解能力，能够作为检索或重排序基座模型。此外，大语言模型还可以为信息检索任务提供高质量标注数据和或用于改写用户查询，进一步提升信息检索模型的性能。在另一方面，信息检索系统能够从其他数据源中为大语言模型提供相关参考信息，能够缓解大语言模型无法获取实时信息与领域信息的问题，进而提升大语言模型在知识密集型任务中的表现。

- **未来方向.** 目前来说，大语言模型与信息检索技术的融合也存在一些技术挑战。首先，大语言模型需要大规模的算力资源支持，在真实信息检索场景中难以广泛进行部署。因此，如何确定大语言模型的应用场景，以及如何将其与小型检索模型进行有效结合，是平衡效率和性能的关键问题。其次，下游场景中并不总是需要检索增强，大语言模型凭借自身内部知识可能就足以支持某些任务。因此，如何设计可以进行主动性触发与使用检索机制是一个值得研究的方向。此外，检索结果中可能包含长度较长的文本内容，而且其中可能存在噪声信息，如何加强大语言模型对于上下文中相关信息的选择与利用，也具有重要的研究意义。




图 13.3 用于推荐任务的大语言模型

13.1.3 推荐系统中的大语言模型

推荐系统的核心在于捕捉并理解用户的潜在偏好，进而为用户推送合适的信息资源。目前，主流的研究工作通常依赖于用户的交互行为日志数据（如点击商品、评论文本数据）来训练推荐模型（通常是深度学习模型）[409]。然而，这些方法在实践中面临着一系列技术挑战，如缺乏通用的知识信息、难以应对冷启动和领域迁移问题等。由于大语言模型具有优秀的语言理解和知识推理能力，近期很多研究工作尝试将其应用在推荐系统领域[208, 410]。下面将从以下三个方面概述大语言模型在推荐系统中的相关研究进展，图 13.3 展示了具体样例。

大语言模型作为推荐模型

大语言模型可以直接作为推荐模型来提供推荐服务。根据是否需要进行参数更新，现有的研究工作可以分为基于特定提示的方法和基于指令微调的方法。

- 基于特定提示的方法. 这类方法通常采用提示学习与上下文学习方法，通过设计一系列自然语言提示来完成多种推荐任务[411, 412]。下面以序列推荐任务为例，介绍如何设计对应的提示方法。首先，可以将用户交互过的物品的文本描述（例如物品标题、描述、类别等）拼接在一起得到一个长句子作为输入文本。然后，结合任务描述构造个性化推荐指令（例如“请基于该用户的历史交互物品向其推

荐下一个合适的物品。”)。此外，还可以在提示中加入一些特殊的关注部分来提高推荐性能，可以强调最近的历史交互物品（例如“注意，该用户最近观看的电影是《肖申克的救赎》。”）和应用上下文学习方法 [413]。然而，由于推荐系统中特定领域的用户-物品协同关系较为复杂且难以通过文本数据充分建模，简单的自然语言提示难以使得大语言模型在性能上与经过充分训练的传统推荐模型竞争。

- **基于指令微调的方法**。这类方法通过微调大语言模型将其适配到推荐系统 [208, 410]，核心在于构建适合推荐任务的指令数据。相关指令可以基于用户与物品的交互数据以及定制化的提示模板来构造，从而为模型提供明确的任务指导。根据物品的表示方式，现有的方法包括以下两种。第一种方法利用文本描述来表示每个物品，该指令构造过程与基于特定提示的方法类似，将用户特征、交互序列等上下文信息整合为纯文本指令用于训练大语言模型。为了构造多样的指令形式，可以采用指令合成技术（如 Self-Instruct），模拟用户在真实场景中产生的个性化指令，以帮助大语言模型理解用户多样化的意图和偏好。具体来说，在包含历史交互记录的基础上，进一步在指令中加入用户当前的意图（例如“现在用户期望购买一个轻便的手提包，请根据该需求提供物品推荐”） [208]。另一种方法是引入传统推荐系统中的索引 ID 来表示每个物品。该方法首先构建物品索引，并使用一个或多个索引 ID 作为物品标识符，然后将这些索引 ID 作为扩展词元加入大语言模型词表。这样，用户的物品交互历史能够被表示为基于索引 ID 的扩展词元序列。这种方法主要具有两个优点。首先，索引 ID 的表示在后续的微调过程中能够专门学习推荐任务相关的物品信息。其次，相较于文本描述，索引 ID 更加具体，有效限定了候选物品的词典空间，易于被模型直接生成。然而，大语言模型所建模的自然语言语义与推荐系统中蕴含的协同语义可能并不一致，故需要设计语义对齐任务以学习 ID 词元的嵌入表示，并将协同信息融入大语言模型的语义空间 [410]。

大语言模型增强的推荐模型

大语言模型还可以用于增强推荐系统的数据输入、语义表示或偏好表示，以从不同角度改进已有推荐模型的性能。

- **数据输入增强**。在数据输入端，大语言模型可以用于用户或物品特征的增强。对于用户特征来说，可以使用大语言模型对用户的交互历史进行推理分析，以此获得更为详细的用户兴趣或蕴含的偏好信息。对于物品特征来说，大语言模型可以被用于从物品文本描述中提取关键属性或者推测缺失的物品特征 [414]。在此基

础上，传统的推荐模型可以利用这些增强后的输入数据实现更为精准的推荐。

- **语义表示增强**. 在中间编码层，大语言模型通常被用来编码用户和物品的描述性信息（例如，物品的标题信息以及用户的评论文本），从而获得用户或物品的文本语义表示，可以将这些富含知识的语义表示作为输入特征，进而增强原有推荐模型的推荐效果 [415]。实际上，早期的预训练语言模型已经通过这种方式在推荐领域中得到了广泛的应用。大语言模型因为其更强大的语义理解能力和丰富的通用知识，能够在冷启动和领域迁移等场景下为模型提供更大的助力。

- **偏好表示增强**. 除了上述两种方式外，还可以通过联合训练大语言模型和传统推荐模型，使两者输出的偏好表示对齐，进而增强推荐模型偏好表示的质量 [416]。该方式类似于知识蒸馏技术，可以将大语言模型的语义建模能力迁移给较小的协同过滤模型，以发挥大小模型各自的优势。在训练阶段完成后，实际部署时使用增强后的小模型即可，从而实现了提升推荐效果的同时，避免了大语言模型带来的大量计算开销。

大语言模型作为推荐模拟器

受自主智能体研究的启发（详见第 11 章），大语言模型进一步被用于设计推荐模拟器，用于仿真用户在推荐系统中的真实交互行为 [114, 310]。推荐模拟器旨在为推荐系统中的每位用户构建一个基于大语言模型的智能体，以模拟他们在真实推荐系统中的交互行为。下面以 RecAgent 为例进行介绍 [114]。为了更好地实现个性化的模拟，RecAgent 为每个智能体都集成了三个核心模块：用户画像模块、记忆模块和动作模块。其中，用户画像模块中包含关于当前用户的相关背景信息（即各种用户属性和特征，如年龄、性别、职业等）。记忆模块负责存储智能体在历史交互过程中的行为以及反馈信息。为了更准确地模拟用户偏好的变化过程，研究人员通常将记忆划分为多个类别，如短期记忆和长期记忆。动作模块则用于模拟用户在推荐系统中的各种行为（如搜索、点击、购买等）。在模拟过程中，智能体借助大语言模型，根据用户画像和历史记忆来执行自我分析与反思，以挖掘潜在的用户行为偏好，之后动作模块基于这些偏好做出决策以确定用户的下一步动作（例如用户对推荐物品进行点击与评分），该动作将会被执行以得到新的用户行为信息。当前大多数推荐模拟器主要基于完全用户导向的设计，侧重于模拟刻画用户的偏好和行为，还可以进一步引入物品侧信息的建模。例如，AgentCF 同时构建了用户和物品智能体，并在优化过程中进一步模拟传统推荐模型的协同过滤思想，建模用户和物品的双边关系来增强个性化推荐 [310]。

总结

下面总结大语言模型应用于推荐系统的建议和未来方向。

- **应用建议.** 大语言模型在用户偏好理解、跨领域推荐、冷启动推荐等复杂推荐场景中展现了较强的性能。然而，受限于高昂的训练和部署成本，在推荐链路中，将大语言模型作为最后重排或精排模型可能更为实际。进一步，可以不直接将大语言模型用于部署，而是在真实场景中有选择性地使用大语言模型（如面临复杂用户行为时）来增强传统推荐模型的数据输入、中间编码或偏好表示，这样可以在避免巨大资源消耗的同时保留传统模型的优势。此外，大语言模型也可以作为推荐模拟器，通过模拟用户和物品的交互行为场景，进而帮助改善用户稀缺场景下的推荐系统服务。

- **现存问题和未来方向.** 目前，大语言模型在应用于真实场景下的推荐系统时依然存在一些亟待解决的问题。首先，在真实世界的应用平台中，推荐系统通常涉及大规模的用户和物品资源。即便仅将大语言模型作为特征编码器，也会带来巨大的计算和内存开销。其次，在推荐系统中，用户的交互历史往往包含长期的、复杂的偏好信息，而大语言模型有限的上下文建模长度可能限制了对这些信息的全面理解和利用。尽管面临诸多挑战，大语言模型在推荐系统中具有广阔的应用前景。例如，大语言模型出色的交互能力与语义理解能力为对话式推荐与可解释推荐都带来了重要的性能提升机会。

13.1.4 多模态大语言模型

多模态大语言模型（Multimodal Large Language Model, MLLM）主要是指那些能够处理和整合多种模态信息（比如文本、图像和音频）的大语言模型。本节内容将以视觉-语言大语言模型¹为例，对相关技术进行介绍，类似的技术也可扩展到其他模态（如音频-语言）。多模态大语言模型的模型结构和训练数据如图 13.4 所示。通常来说，多模态大语言模型主要由一个用于图像编码的视觉编码器和一个用于文本生成的大语言模型所组成，进一步这两个模型通过连接模块进行组合，从而将视觉的表示对齐到文本语义空间中。在文本生成的过程中，图像首先被分割成图像块（Patch），然后通过图像编码器和连接模块转换成图像块嵌入，以得到大语言模型可以理解的视觉表示。随后，图像块嵌入和文本嵌入进行拼接并输入到大

¹除了多模态大语言模型以外，大型视觉语言模型（LVLMs）也被用来指代这种基于大语言模型的双模态模型。我们在这部分使用多模态大语言模型这一术语，因为它在当前研究界被广泛使用。




图 13.4 多模态大语言模型的架构和训练过程

语言模型中，使得大语言模型可以自回归地生成文本回复。下面将讨论多模态大语言模型的训练、评测、代表性模型，以及应用建议与未来方向。

训练过程

多模态大语言模型的训练过程主要包括两个阶段：视觉-语言对齐预训练和视觉指令微调，图 13.4 展示了具体样例。

- 视觉-语言对齐预训练. 为了训练多模态大语言模型，一般重用已有的视觉编码器和语言模型 [417–419]。由于视觉模型和语言模型之间存在较大的语义空间差异，因此视觉-语言对齐预训练旨在利用大规模“图像-文本对”（简称图文对）进行端到端训练，进而对齐两种不同的语义空间。为了提高对齐性能，选择合适的训练策略和数据非常重要。下面给出一些经验性的训练策略：（1）如果图文对数量不足够大（例如少于 1M），通常只更新连接模块 [420]；（2）如果训练数据规模相对较大，且包括高质量文本语料或具有细粒度标注的图像-文本对，可以微调大语言模型以提升性能 [421]；（3）如果图文对的数量非常大（例如 1B 规模），可以进一步微调视觉编码器 [422]。以上方案均来源于经验性的实验，在使用中仍需进一步验证确定。

- 视觉指令微调. 在视觉-语言对齐预训练之后，下一阶段需要进行视觉指令微调，旨在提高多模态大语言模型遵循指令和解决任务的能力。一般来说，视觉指令微调的输入包括一张图像和一段任务描述文本，输出是对应的文本回复。为了

构造高质量的视觉指令数据，可以将图像自带的描述文本输入给大语言模型（如 GPT-4），通过特定的提示（如“根据图像描述生成一段图像相关的对话”）来引导大语言模型自动化地合成视觉指令 [418]；或者基于已有的视觉-语言任务数据集，利用特定的问题模板将原有任务数据转化为视觉指令（如“请参考图片回答以下问题并给出详细解释”） [423]。

多模态大语言模型的评测

在介绍完多模态大语言模型的构建方法后，下面进一步讨论如何评测多模态大语言模型的多模态能力，将从评测维度、评测范式和评测基准三个方面进行介绍。

- **评测维度.** 多模态大语言模型的评测任务主要可以被划分为两类：视觉感知和视觉认知任务。具体来说，视觉感知任务旨在评测模型对于图像内容的基本理解能力，而视觉认知任务要求模型根据图像内容完成相对复杂的推理任务。视觉感知任务常用的评测数据集主要关注于对图像整体特征（如主题、风格等）或图中物体特征（如颜色、数量、位置关系等）的识别和分类。特别地，模型对于图片的感知结果与图片实际内容可能存在差异，这种现象被称为幻象问题，可以进行专门的幻象评测（如使用物品幻象评测基准 POPE [351]）。视觉认知任务主要关注于利用语言模型中的语义知识和图像中的视觉感知信息，进而完成更复杂的视觉相关推理任务。其中，视觉问答（Visual Question Answering, VQA）是被广泛用于评测的认知任务，其通过构造和图片内容相关的推理问题来测试模型性能。问题涉及的内容可以是给出的图片中物体之间的空间位置关系（如“图中的碗是在绿色苹果的右侧吗？”）、常识知识（如“图中的人物应该通过哪种动作才能打开这扇门，推还是拉？”）或场景文字（如“图中车辆的车牌号是多少？”）等。

- **评测基准.** 为了更全面地评测多模态大语言模型，学术界发布了多个综合评测基准。这些评测基准整合了已有的多模态数据集，并且增加了借助人类或大语言模型进行标注的评测任务。其中，三个常用的评测基准包括：（1）MME [424] 主要包括了从公开途径获得的图片配上手工收集的自然语言问题，这些问题的答案形式被限定为是或否，用于评测多模态大模型在 14 个视觉感知和认知任务上的表现；（2）MMBench [425] 基于现有数据集，手工构造了 2,974 条用于评测多模态能力的多项选择题，总共涵盖了 20 类不同的多模态任务；（3）MM-Vet [426] 首先定义了 6 项基础的多模态能力，之后将这些能力组合为 16 种不同的复杂多模态任务，之后收集了 200 张图片和 218 个文本问题用于评测。

代表性的多模态大语言模型

近年来，学术界和工业界涌现出了多种多模态大语言模型。下面介绍一些具有代表性的多模态大语言模型。

- *MiniGPT-4* [419]. MiniGPT-4 是较为早期的开源多模态大语言模型，主要包括三个组件：CLIP 和 Q-Former 组成的视觉编码器，对齐视觉和语言特征表示的线性层，以及大语言模型 Vicuna。MiniGPT-4 的训练经历两个阶段：首先是视觉-语言对齐的预训练阶段，此阶段主要使用了来自 LAION, SBU 和 Conceptual Captions 的大量图文对数据集，针对模型的线性层进行训练，旨在为模型建立初步的跨模态理解能力。进一步，在视觉指令微调阶段，作者收集了 3,500 条高质量的详细图片描述，并将其组织成对话形式进行模型微调，以提高模型的语言流畅度和对话交互能力。这一阶段也仅针对线性层进行训练。

- *LLaVA* [418]. LLaVA 也是早期的开源多模态大语言模型之一，其模型结构与 MiniGPT-4 类似，但视觉编码器部分仅由 CLIP 组成。LLaVA 在视觉-语言对齐预训练阶段，从 CC3M 中收集了 595K 图文对数据来训练线性层；在视觉指令微调阶段利用 ChatGPT 改写了 COCO 数据集中的图文对，创建了 158K 条复杂视觉指令数据，涵盖了图像描述、看图对话和视觉推理等类型的任务，然后使用这些数据同时训练大语言模型和线性层。LLaVA 后续还推出了 LLaVA-1.5 和 LLaVA-Plus 等加强版本。其中，LLaVA-1.5 增加了视觉-语言表示对齐的线性层的参数，并在训练数据中加入了更多任务相关数据（如知识问答和场景文字识别）以进一步提升模型能力。

- *GPT-4V* [56]. OpenAI 在 2023 年 3 月的技术报告中首次介绍了 GPT-4V 的多模态能力，针对照片、截图、图表等多种图片形式，GPT-4V 均能有效回答与其相关的自然语言问题。2023 年 9 月，OpenAI 正式发布了 GPT-4V 的系统概述，重点介绍了其在安全性对齐方面的进展，能够有效避免有害内容的输出。2023 年 11 月 6 日，OpenAI 向公众开放了 GPT-4V 的 API 接口。已有评测工作表明，GPT-4V 不仅在文本任务上领先此前的模型，在传统 VQA 任务（例如 OK-VQA）以及针对多模态大模型的复杂评测基准（如 MMMU）上的表现也都处于领先水平。

- *Gemini* [71]. 2023 年 12 月 14 日，谷歌推出了 Gemini 系列大模型，其中发布了多模态模型 Gemini Pro Vision 的 API。技术报告中提到，Gemini 采用的是纯解码器架构，能够处理文本、音频和视觉模态的输入，并能生成文本或图像的输出。它的训练数据涵盖了从网页、书籍、代码到图像、音频和视频等多样的数据

来源。在各种评测基准上的测试结果表明，Gemini 不仅在文本生成和理解方面表现出色，还能够完成视频理解、音频识别等其他模态任务。

总结

基于以上讨论，我们对多模态大语言模型给出了以下应用建议和未来方向：

- 应用建议. 现有的评测结果表明，闭源模型（如 GPT-4V、Gemini 等）的通用多模态数据处理能力普遍优于开源的多模态大语言模型。然而，闭源模型不利于进行端到端或者增量式的应用开发。因此，对于特定的多模态任务场景，如果能够针对性地构造高质量多模态指令数据并对开源模型进行训练，也是一个重要的技术路线。此外，由于真实应用场景较为复杂，直接利用多模态大语言模型可能并不能有效应对所有复杂案例，还可以考虑让多模态大模型学习使用其他工具（如图像分割模型等），从而加强多模态模型的任务效果。

- 未来方向. 尽管目前的多模态大语言模型已经初步具备了基于视觉信息进行推理的能力，但是其在复杂多模态应用场景下的效果仍然非常受限，如基于多图的复杂逻辑推理问题、细粒度的语义理解问题等。为了加强多模态模型的复杂推理能力，可以构造覆盖场景更广且更加复杂的视觉指令集合以强化模型本身的视觉推理能力，而更为本质的问题是去思考多模态大模型的建立方法与学习机制。例如，Gemini 从头对于多模态数据进行混合预训练，而不是将多模态组件直接向大语言模型进行对齐。此外，多模态大语言模型可能输出虚假或有害的信息（如物体幻象），这会对于模型的安全性造成很大影响。针对这一问题，既需要在模型层面分析幻象的导致原因（如图片侧防御能力较弱等），也可以通过收集类似红队攻击或幻象识别的视觉指令，用来微调多模态大语言模型以增强其健壮性。

13.1.5 知识图谱增强的大语言模型

尽管大语言模型具有出色的自然语言生成能力，但在知识密集型任务中常常面临一些挑战，例如可能生成幻象或事实错误内容。因此，在一些特定场景中，需要向大语言模型补充外部的知识信息。知识图谱（Knowledge Graph, KG）存储了大量的结构化知识信息，常用于知识密集型的任务场景，也广泛被用于补充大语言模型的知识信息。本部分将从两个方面讨论如何使用知识图谱增强大模型，包括基于子图检索的方法和基于查询交互的方法。图 13.5 中展示了这两类方法的整体流程，其中基于检索的方法首先从知识图谱中检索知识，然后注入大语言模型；基于交互的方法支持大语言模型多次查询知识图谱从而动态地获取外部知识。




图 13.5 知识图谱增强的大语言模型

基于子图检索的方法

基于检索增强的方法通常首先从知识图谱中检索一个相对较小的子图（知识检索），然后将该子图序列化并作为提示的一部分，输入给大语言模型以丰富其相关背景知识（知识利用）。对于知识检索，可以使用启发式方法过滤掉知识图谱上不重要的节点。这类方法通常使用 **PageRank** 等图节点排序算法来计算知识图谱上每个节点的重要性，并按照预先设定的阈值筛选出重要的节点以构成规模相对较小的子图。然而，这种方法仅利用了知识图谱的结构特征，没有考虑节点与输入文本在语义信息上的相关性。另一类有效的方法是训练语义匹配模型（例如预训练语言模型），专门用于筛选与问题相关的事实三元组 [427]。由于知识图谱中三元组规模庞大，可以基于输入文本中包含的实体，对与其相邻的若干跳以内的三元组进行筛选。对于知识利用，通常是将检索到的子图序列化，并设计特定的提示将其作为大语言模型的输入 [428]。具体来说，给定上述的检索子图，可以从起点开始按照图结构进行广度优先遍历，得到子图上三元组的拓扑排序。然后将每个三元组涉及的头实体，关系，尾实体按序排列，并使用特殊标记进行分隔，得到最终的知识序列。然而，由于知识序列化这一过程会不可避免地丢失结构化信息，使得大语言模型无法完全建模原始知识图谱所传达的结构语义。

基于查询交互的方法

基于查询交互的方法主要通过大语言模型与知识图谱之间的多轮交互过程，动态地获取当前步骤需要的信息，以增强大语言模型利用知识图谱信息的能力，从而更好地解决复杂任务（如多跳问题回答 [429]）。具体来说，大语言模型需要首先规划复杂任务的解决方案，将原始复杂任务分解为多个相对简单的子问题，然后通过与知识图谱进行交互，迭代地获取所需知识信息以解决每个子问题。为了支持大语言模型精确地查询知识图谱中的信息，可以基于结构化的程序语言（如 SPASQL），设计面向知识图谱的专用接口函数，使得大语言模型可以通过函数调用与执行的方式获取相关信息 [264]。在这一过程中，大语言模型可以被看作是一个自主信息获取的智能体（详见第 11.2 节），知识图谱可以被视为外部环境，其中每一步抽取得到的结构化数据可以看作是环境反馈。在这种设定下，大语言模型可以自主规划如何与知识图谱环境进行交互，最终实现问题的求解。

总结

下面给出针对知识图谱增强的大语言模型的应用建议和未来研究方向。

- **应用建议.** 知识图谱不仅包含丰富的事实性知识，还能够帮助大语言模型理解知识之间的语义关联。通过结合知识图谱与大语言模型，可以显著提升模型在知识密集任务中的效果。在实际应用中，可以根据任务的特性与需求来决定具体的策略：对于简单的知识利用任务（不涉及多步推理），可以直接从知识图谱中检索相关信息，并将其作为提示的一部分输入给大语言模型；对于需要多步推理求解的复杂任务，可以设计基于知识图谱的基础查询函数，用于支持大语言模型与知识图谱的动态交互机制，进而通过多次调用函数以逐步求解问题。

- **未来方向.** 为了改进大模型对于知识信息的利用，可以从以下三个方面进行深入探索。首先，由于知识图谱表达形式的多样性（例如不同的知识图谱具有不同的关系和实体类型），大语言模型仍然难以通过统一的途径利用各种类型的知识图谱。因此，需要设计通用的知识整合与利用技术，使得大语言模型可以通过统一方式去获取与利用广泛的知识图谱中的知识信息。其次，大语言模型中编码的知识信息可能会出现过时或不正确的现象，存在与外部知识库冲突的问题。因此，需要探索如何消解可能存在的知识信息，并且高效地将正确的知识信息融入到大语言模型中。最后，如何利用知识图谱中的事实信息来改善大语言模型的对齐能力与准确性 [430]，使其生成更为精准的回复并减少幻象内容，也是值得探索的问题。

13.2 大语言模型在专业领域的应用

除了在研究领域中带来了重要影响，大语言模型目前也广泛地应用到了各种专业领域，进而推动相关技术的改进与升级。本节内容将以医疗、教育、法律、金融和科学研究五个领域为例，概要介绍一下大语言模型在这些专业领域内的应用情况，表 13.1 展示了各领域的代表性大语言模型和数据资源。

13.2.1 医疗场景下的大语言模型

医疗是与人类生活密切相关的重要领域之一。由于具有较强的通用任务解决能力，大语言模型被广泛用于辅助医生处理各种相关医疗任务，例如医疗诊断、临床报告生成、医学语言翻译、心理健康分析等 [431]。为了充分发挥大语言模型在医疗领域的作用，研发医疗相关的大语言模型非常重要。

构建面向医疗的大语言模型

已有的医疗大语言模型主要以通用大语言模型为基础，通过继续预训练技术或者指令微调方法 [431]，让其充分适配医疗领域，从而更好地完成下游的医疗任务。在继续预训练阶段，医疗大语言模型可以利用医学领域丰富的数据资源（如医学教材、诊断报告等），学习医学领域的专业知识与相关技术，进而准确理解医学文本数据的语义信息。为了解决复杂且多样的医疗任务，还需要进一步构建特定的指令集合对模型进行指令微调。在真实场景中，医疗相关指令数据相对较少，可以通过收集医患对话数据或医学问答数据集，在此基础上设计指令模板，来构造面向不同医疗任务的指令数据。Med-PaLM 模型 [206] 是谷歌推出的医疗大语言模型，其通过医疗相关的指令数据对 FLAN-PaLM 进行微调，在回答医疗问题时获得了专业医生的认可。为了增强模型回答的准确性和可信程度，还可以将医疗大语言模型和医学数据库进行结合，利用检索增强等方法来提升模型在处理复杂医疗任务时的能力。

此外，现有的医疗大语言模型通常基于英文语料进行训练，可能无法充分覆盖中医相关的知识体系。为了研发中医相关的医疗大语言模型，可以利用现有中医语料库构造预训练数据和微调指令，进而提升对于传统中医理论的理解与应用能力。进一步，在医疗领域中，影像信息具有重要的数据价值（X 光片、MRI 光片等），能够提供关于患者病情的直观信息。因此，构建能够理解医疗文本和视觉信息的多模态大语言模型，有着较大的应用前景。为了实现这一目标，可能需要

表 13.1 各专业领域内代表性的大语言模型与数据资源

领域	资源类型	细分类别	名称
医疗	模型	预训练大语言模型	GatorTronGPT, MEDITRON
		指令微调大语言模型	ChatDoctor, DoctorGLM, Med-PaLM
		多模态大语言模型	BenTsao, HuatuoGPT, DISC-MedLLM
	数据集	预训练数据集 中文医学知识图谱	VisualMed-Alpaca, LLaVA-Med
教育	数据集	预训练数据集	Clinical Guidelines, PubMed, MIMIC-III
		中文医学知识图谱	CMeKG
		医学领域问答 医学多模态问答	MedMCQA, PubMedQA, MultiMedQA
	评测基准	医学领域问答 医学多模态问答	VQA-RAD
法律	模型	指令微调大语言模型	EduChat, 智海-三乐, 子曰大模型
		下游应用工具	Khanmigo, Duolingo Max, EmoGPT
		教育对话数据集	TSCC, ESConv
	数据集	问答数据集	TAL-SCQ5K
金融	数据集	教育领域问答	AI Teacher Test, CALM-EDU, E-EVAL
		指令微调大语言模型	ChatLaw, PowerLawGLM, LaWGPT, LexiLaw
		下游应用工具	通义法睿
	数据集	论文数据集	CUAD, LeCaRD
科学	数据集	问答数据集	中国司法考试题, 百度知道法律问答
		法律领域问答	LexGLUE, LegalBench
		预训练大语言模型	BloommbergGPT, XuanYuan 2.0
	模型	指令微调大语言模型	FinMA, FinGPT, InvestLM
科学	数据集	预训练数据集	BBT-FinCorpus
		指令微调数据集	FIT
		金融领域问答	FLUE, BBT-CFLEB, FinBen
	评测基准	金融领域问答	FLUE, BBT-CFLEB, FinBen
科学	模型	预训练大语言模型	Galactica, AcademicGPT, LLEMMA
		指令微调大语言模型	DeepSeekerMath, ChemDFM, GeoGalactica
		指令微调大语言模型	LLaMA-SciTune, SciGLM, DARWIN
	数据集	学术论文 指令微调数据集	Arxiv, OpenReview, Unpaywall
科学	数据集	指令微调数据集	SciInstruct, Mol-Instructions
		指令微调数据集	SciInstruct, Mol-Instructions
		指令微调数据集	SciInstruct, Mol-Instructions
	评测基准	科学领域问答	SciEval, Sci-Bench, PubMedQA
科学	评测基准	科学领域问答	CEval/MMLU-Sci, ChemLLMBench
		科学领域问答	CEval/MMLU-Sci, ChemLLMBench
		科学领域问答	CEval/MMLU-Sci, ChemLLMBench
	评测基准	科学领域问答	CEval/MMLU-Sci, ChemLLMBench

针对性地设计医疗图文指令。例如，可以对病灶区域进行专业标注，并设计对应的病情诊断指令。

数据资源

医疗领域有许多开源的数据资源可用于模型的训练与评估。其中，预训练医疗大模型的数据来源主要包括电子病历、科学文献和医学问答等。电子病历数据通常由病人的健康诊断数据构成，该类数据能够帮助大语言模型理解医疗领域术语，并学习医疗诊断和分析方法。MIMIC-III [432] 是目前被广泛使用的电子病历数据集，共包括 40K 余名病人的健康数据，覆盖医生诊断、生命体征测量、医学影像、生理数据、治疗方案、药物记录等信息。作为另一种重要预训练数据源，科学文献中包含了许多与医疗领域研究相关的学术研究文档，并且普遍具有较为规范的格式。此外，医疗领域还存在大量的医学问答与医患对话数据，这些数据常用来构建指令数据集，用于医疗大模型的指令微调。

为了对医学大语言模型进行评测，通常使用医学问答数据以自动化地评估医学文本理解以及医学知识利用的能力。其中，MultiMedQA [206] 是一个被广泛使用的医学问答评测基准，共由 7 个医学问答数据集组成，包含了来自多个医学领域的问答对，涵盖了临床医学、生物医学等健康相关的多种主题。此外，针对多模态医疗大模型，常使用包含医学影像和与之相关的问答对数据对其进行评测，其侧重于评测模型对医学图像的理解能力以及对图文模态信息的综合利用能力。除了利用开源的数据资源进行自动评估，也可以通过邀请专业医生参与医疗大语言模型的评估，确保模型在实际临床应用中的安全性和有效性。该类方法通过让医学专家或临床医生审查模型生成的文本，从医学领域的准确性、临床适用性和专业性等角度，评估该模型生成内容的准确性和可靠性。

总结

在医疗领域，大语言模型展现出了较好的应用前景。通过利用医学数据进行预训练或微调，大语言模型可以初步理解医学知识，能够在医疗研究、临床诊断、药物开发等各个方面为人类提供服务，这对于改善医疗服务质量、提升医疗健康水平具有重要的实践意义。然而，已有的医疗大模型仍然很难充分掌握医学领域专业知识，无法精确感知医疗健康数据的数值含义，在实际应用中也缺乏自主的安全监管手段。这些问题都有待深入探索。此外，将医疗大语言模型与其他医疗技术（如生物传感技术等）相结合，有望形成一个更完整、更智能的医疗辅助系统。

13.2.2 教育场景下的大语言模型

教育是人类社会进步的基石，对个人和社会发展都至关重要。在教育系统中，大语言模型已经被用于多种教育相关任务，有助于增强教育场景的智能化、自动化和个性化 [433]。

构建教育相关的大语言模型

通常来说，教育应用系统面临着多样的用户需求（如作文批改、启发式教学、试题讲解等），而且要支持与用户进行便捷的交互。为此，教育大语言模型需要基于海量的教育相关文本和专业数据对大模型进行训练，并结合大规模的对话数据进行指令微调，从而适配教育应用场景下的多种需求 [433]。考虑到教育领域不同学科往往具有显著的知识差异，还可以针对各学科设计专用的教育大模型。例如，可以构建专门面向数学学科的垂域大模型，强化数学学科特有的定理公式等专业知识，并能提供具有启发性的结题过程，以适应数学辅导的实际应用需求。在此基础上，也可以将各学科的垂类模型集成为一个综合教育系统，从而为多学科提供全方位的教学支持和服务。此外，也可以通过集成网络检索增强和本地知识库等功能，在实际应用时提升在特定场景下教育大模型的效果。然而，由于教学数据可能包含用户隐私，使用其训练后的大语言模型可能存在隐私泄露的风险。因此，目前的开源教育大模型较少，已有的模型普遍通过向用户提供 API 的方式对外服务。

数据资源

教育领域大模型相关的数据资源主要包括两类，即适配教育场景的训练数据和衡量大模型教育能力的评测数据。

其中，教育大模型所用的预训练数据通常来源于学科教材、领域论文与教学题库，这些数据能够在预训练阶段为大语言模型注入学科领域的专业知识。进一步，也可以邀请人类专家或使用大语言模型将其改写为指令数据，用于对大语言模型进行指令微调。例如，邀请专家标注题目解析指令数据，或使用 ChatGPT 仿真教学场景下的师生对话 [434]。此外，也可以从真实教育场景或在线教学平台中，利用录音、录像等形式采集真实学生数据，用于构造指令数据 [435]，例如教师和学生之间的真实对话。师生聊天室语料库（Teacher-Student Chatroom Corpus, TSCC）[435] 收录了 102 个不同教室内匿名师生的真实对话，总计十万多个对话轮次。在每轮对话中，教师和学生进行语言练习并评估学生的英语能力，同时提供个性化

的练习和纠正，故该数据集可以用于教育场景下的指令微调。

对教育领域大模型的评估主要关注于以下两个方面：在辅助学习过程中的教学能力和对教育领域知识的理解能力。对前者的评测需要收集现实世界中教师与学生的对话，然后利用大语言模型模拟人类教师对学生进行教学指导，从表达方式、理解能力、辅助教学等方面分别进行评估 [436]。进一步，对后者的评测可以直接针对知识层次和学科特点，选择合适的已有教学题库进行测评。

总结

大语言模型在教育领域中展现了较好的应用潜力，不仅可以在教学过程中进行指导，还可以辅助进行课程规划与作业评测 [434]。然而，教育场景下大模型的应用仍然存在一系列技术问题。首先，大语言模型可能出现幻觉或者错误推理问题，导致它在教学场景下不能完全正确地执行解题、课程规划等任务。其次，大语言模型可能生成有偏见、有道德风险等不符合人类教育价值取向的内容，可能会不利于思想品德和政治等学科的辅助教学 [433]。此外，学生对于大语言模型的过度依赖还可能引发工具滥用问题，从而可能导致作业抄袭、考试舞弊等情况的出现，需要教育人员引起重视并制定相关的政策规范。针对上述问题，相关技术人员需要设计相应的改进方案，从而更好将大模型技术服务于教育领域。

13.2.3 法律场景下的大语言模型

在法律领域，相关从业人员需要参与合同咨询、审查、案件判决等日常重复性任务。这些任务需要耗费大量的人力成本，亟需面向法律领域的人工智能技术辅助完成这些工作，从而减轻从业人员的工作负担 [437]。大语言模型具有优秀的模型能力，经过领域适配以后，能够助力完成多种法律任务，如合同信息抽取、法律文书撰写和案件判决生成，具有较好的应用场景。

构建法律相关的大语言模型

为了构建法律大语言模型，可以采集大量的法律相关的文本数据，进而针对通用大语言模型进行继续预训练或指令微调，使其掌握法律领域的专业知识。ChatLaw [438] 是一个面向中文的法律大语言模型，其训练数据主要来源于法条、司法解释、法考题、判决文书、法律相关论坛和新闻等。ChatLaw 目前主要有两个版本，即 ChatLaw (13B) 和 ChatLaw (33B)，分别基于 Ziya-LLaMA (13B) 和 Anima (33B) 基座模型训练获得，具有较好的法律文本理解与任务处理能力。由于法律领域具

有高度的专业性、且不同国家法律存在差异，在训练法律大模型时需要考虑其适用范围。例如，在中文法律场景下，需要在构造训练数据时去除不符合中国法律的相关训练数据，并且针对常见的法律案例、咨询需求等构造指令数据集 [438]，从而更准确地理解中国用户的法律需求。

数据资源

法律领域有许多可用于模型训练与评估的数据资源。其中，可用于训练法律大模型的数据资源主要包括法律法规、裁判文书等法律数据。这些数据通常可以从相关官方网站下载获得，且数据规模较大，能够为大模型提供大量的法律专业知识。进一步，还可以收集司法考试题目、法律咨询、法律问答等相关数据，此类数据涉及了真实用户的法律需求与基于法律专业知识的解答，通常可以用于指令数据的构造，进而对于模型微调。Cuad [439] 是一个包含 510 个商业法律合同、超过 13K 个标注的合同审查数据集，由数十名法律专业人士和机器学习研究人员共同创建。通过法律专业人士对这些合同数据进行扩充和详细标注，可以得到高质量的法律相关指令数据，从而提升法律专用垂直大模型的微调效果。

此外，上述数据也可以用来构建法律领域的评测基准，用于全面评估法律专用的大语言模型的性能。其中，司法考试题目常用于对模型进行评测，相较于传统问答数据集，司法考试题目的问答依赖于对大量专业知识的理解，以及对大量相关资料的参考结合，因此具有较高的难度与专业度，可用于法律大模型的综合能力评估。

总结

大语言模型对于推动法律领域的技术自动化升级有着重要应用意义。在实践中，可以通过使用法律领域数据进行预训练和指令微调，增强通用大语言模型对于法律知识的理解和利用，进而有效适配法律领域的应用任务。由于法律领域的应用场景对准确性和严谨性要求较高，实际应用中仍然需要专业人员进行核对，从而保证输出结果的专业性和可靠性。此外，法律领域还需要考虑个人隐私保护，防止模型出现隐私信息的泄露。

13.2.4 金融场景下的大语言模型

随着金融科技快速发展，金融领域对于自动化的数据处理和分析技术日益增长。在这一背景下，大语言模型技术开始逐步应用于金融领域的多种相关任务

(如投资倾向预测、投资组合设计、欺诈行为识别等), 展现出了较大的应用潜力。

构建金融相关大语言模型

与前述垂域模型的研发方法相似, 可以将通用大语言模型在金融领域数据上进行继续预训练或指令微调, 进而构建金融大语言模型, 提高其在金融相关任务上的表现。为了训练金融大语言模型, 需要收集大量的金融领域文本数据, 通常还可以再添加通用文本数据以补充广泛的语义信息。其中, 可供使用的金融领域数据主要包括公开的公司文件、金融新闻、财务分析报告等, 可以为大语言模型补充金融领域的专业知识。其中, 一个具有代表性的金融大语言模型是 BloombergGPT [210], 该模型采用自回归 Transformer 模型的架构, 包含 50B 参数, 使用了 363B 词元的金融领域语料和 345B 词元的通用训练语料从头开始预训练。其中, 金融领域数据主要来自于彭博社在过去二十年业务中所涉及到的英文金融文档, 包括从互联网中抓取的金融文档、金融出版物、彭博社编写的金融新闻以及社交媒体等。BloombergGPT 在金融评测基准上的表现优于 OPT、BLOOM 等通用开源大语言模型, 并且在通用自然语言评测基准上能达到这些通用大语言模型相近的性能。

数据资源

金融领域的预训练数据通常包含公司与个人的专有信息, 可能会涉及到隐私问题, 因此开源数据相对较少。目前研究社区公开的金融领域数据资源主要为指令和评测数据集。

已有的指令数据集通过整合金融领域的各类任务数据(例如新闻标题分类、命名实体识别、股票趋势预测)和现实应用场景中的问答或对话数据(例如注册金融分析师考试、在线平台上金融讨论帖等), 并将其整理为统一形式的指令数据, 用于提升模型对金融领域文本的理解能力和在现实金融场景中的实用性。FIT [440] 是一个较具代表性的金融指令数据集, 共包含 136K 条指令。其原始数据来源于 9 个金融领域自然语言数据集, 涵盖了 5 类金融自然语言任务。

为了对金融大语言模型进行评测, 已有的金融领域评测基准涵盖了多种金融领域的任务。其中, FinBen [441] 收集了 35 个金融相关数据集, 共涉及 23 类不同任务。这些任务根据难度被分为 3 个级别: (1) 基础任务由金融领域的分类或计算任务组成, 例如要求模型分析金融文本的情感取向或者根据财务表格进行数值推理; (2) 进阶任务关注于更复杂的生成与预测任务, 例如根据历史信息预测股票趋势的变化以及生成金融新闻的摘要等; (3) 具有挑战性的任务旨在自动化生成交易决策, 要求模型根据历史股价、公司财报等多方面信息做出面向股票市场

的交易决策，这一任务综合衡量了模型的信息决策能力与风险管理能力。

总结

大语言模型在金融领域的应用正处于快速发展之中，其应用范围逐步扩展，在提升金融行业效率、增强决策质量方面具有较好的应用潜力。然而，金融领域数据可能会涉及隐私问题，目前开放的数据资源相对较少，尤其缺乏大规模的金融预训练数据集，需要进一步进行建设与补充。此外，金融领域还存在大量格式化的数据（表格、时间序列数据等），这需要语言模型具备特定的数据处理能力，或者能够结合适配的模型与工具进行分析和处理。

13.2.5 科学研究场景下的大语言模型

科学研究是研究人员探索科学问题的学术活动，对于人类社会的发展与进步有重要意义。在科研过程中，研究人员往往需要面对复杂的科学问题，处理与分析大量的实验数据，并需要及时学习最新的科学进展。在这一过程中，可以使用大模型技术来辅助人类的科研探索工作，进而推动科学研究的快速进展。

构建科学研究相关的大语言模型

通过使用科学领域相关的数据对大语言模型进行预训练或微调，可以使其适配于科学研究场景下的各类任务。Galactica [442] 是 Meta AI 公司于 2022 年 11 月推出的科学大模型，该模型通过在 48M 篇论文、教科书和讲义、数百万个化合物和蛋白质、科学网站、百科全书等大量科学相关数据上预训练得到的。实验结果表明，Galactica 可以解决许多很多复杂科研任务，包括辅助论文撰写、物理问题求解、化学反应预测任务等。此外，对于特定的科学领域（如数学、化学、生物等），也可以通过收集领域特定的数据集，针对性训练特定的大语言模型。

在研发科学领域的大语言模型时，需要选择合适的基座模型和高质量的训练数据。例如，对于数学等理工学科，可以采用基于代码的大语言模型作为基座模型，并需要收集大量包含形式化的文本（如包含有公式、定理证明等）作为预训练数据 [156]。此外，在设计面向科学研究场景的指令数据时，需要尽量覆盖相关任务场景下的基础任务（如科学概念理解和问答）与特殊的应用需求（如数值计算和定理证明）[443]，还可以针对性地适配特殊的数据形式（如化学表达式），从而更为精准地解决领域内的应用需求。

数据资源

目前有很多开放的数据资源可用于研发科研大语言模型。其中，公开的学术论文被广泛用作预训练数据。**arXiv** 作为全世界最大的论文预印本收集平台，其收录了近 2.4M 篇学术文章，涵盖物理学、数学、计算机科学、定量生物学等领域，提供了非常高质量的科研文本数据。除此之外，研究人员还可以通过其他科研论文平台进行数据的收集，如 **PubMed** 和 **Semantic Scholar**，进一步扩充学术论文的范围与规模。由于科学领域数据可能包含特殊格式的数据（如蛋白质序列等），通常需要对其进行专门的处理，使其转换为统一的文本表示形式（如转成 **Markdown** 格式）[442]。此外，科学领域还存在大量的开源问答数据集，如专业考试习题、社区问答数据等，这些数据经常用于构造指令数据集，以帮助大模型进行指令微调。

为了评测大语言模型对于科学知识的掌握程度，科学领域的问答数据也被广泛用于大模型的能力评测。这些任务不仅需要模型理解基本的科学概念与理论知识，还需要具有多步推理与复杂计算的能力。其中，**Sci-Bench** [444] 是一个代表性的科学知识评测基准，该评测基准构造了一个大学程度的科学问题数据集，涵盖了从化学、物理和数学教科书中收集的 789 个开放性的问题。进一步，该评测基准还包括了一个多模态子集，可以用于评估多模态大语言模型解决科学问题的能力。

总结

随着大模型技术的不断发展，大语言模型对于科学研究的支持将会日益增强，可以覆盖到多个科研环节，包括文献调研总结、辅助科研思考、数据分析、论文撰写。与其他领域相比，科学领域内的一些特定任务（如解析几何问题等）具有较高的难度，对于大语言模型的推理与计算能力提出了较大的应用挑战。在未来的研究中，需要不断探索大语言模型的能力提升方法，加强模型对于复杂问题的求解效果。此外，为了打造高效、可信的科学助手，还需要进一步提升大语言模型生成内容的科学质量，并需要有效地减少幻觉现象。