

第十四章 总结

在前述内容中，本书重点介绍了大语言模型的基础知识、重要概念以及关键技术，主要围绕预训练、指令微调、人类对齐、模型使用和能力评测等多个方面进行了相关讨论，此外还汇总了大语言模型的相关公开资源，并提供了部分技术的实践代码作为参考。最后，本书介绍了大语言模型在研究领域以及专业领域的应用情况。

接下来，将针对四个方面对于本书所讨论的内容进行总结，并概要介绍大语言模型面临的挑战和未来可能的研究方向。

基本原理

大语言模型采用了看起来非常简单的训练任务（即预测下一个词元），通过在大规模文本数据上进行无监督预训练，就能获得解决各种下游任务的通用潜力。这种学习方式与传统的多任务学习方法有很大不同，之前的方法通常需要尽可能地扩展训练任务或者标注数据以获得较好的多任务学习能力。

尽管大语言模型的基本思想比较容易理解，但要形式化解释为什么通过简单的语言建模目标（预测下一个词元）训练得到的大语言模型能够解决各种复杂任务，仍然具有很大的研究挑战。为此，深入剖析大语言模型能力的学习机理已经成为学术界的重要研究目标。由于目前大模型的架构相对固定，目前大语言模型的模型能力很大程度上依赖于预训练数据的清洗、配比与训练课程。基于此，一个关键问题就是模型如何通过对于预训练数据的学习建立起优秀的通用任务能力。

值得一提的是，扩展模型规模与数据规模是本次大模型成功的重要因素，而扩展法则对于探究大语言模型的能力提升具有一定的指导作用 [23, 24, 123]。未来的研究工作可以进一步完善已有的研究成果，可以针对大模型与小模型之间的行为关系开展更多的理论分析，进一步可以探究大模型的哪些行为可以基于小模型进行预测、哪些则不能准确预测。

此外，越来越多的工作开始关注大语言模型是否能够掌握预训练数据之外的知识与能力，对于大语言模型的泛化性分析也是未来的一个重要研究方向。最近，评测集合的数据污染已经成为大语言模型公平评测的一个严重问题 [136]，如何构建独立于预训练数据之外的评测集合并设计针对性的评测方法，需要更多研究工作的关注。

模型架构

由于具有良好的可扩展性，由堆叠的多头自注意层组成的 Transformer 已经成为构建大语言模型的基础网络架构。为了进一步提高该架构的模型性能，研究人员提出了各个模块进行了相关改进（见第 5.2 节的讨论）。

然而，Transformer 模型仍然受到训练成本高、推理速度慢等问题的困扰，设计更为适配大模型的模型架构具有重要的研究意义 [188, 189]。为此，本书也针对基于参数化状态空间模型所提出的新型模型架构进行了相关介绍（第 5.5 节），然而这些新型架构的性能仍然需要进一步的验证与优化。此外，在探索架构改进的工作中，系统级别以及硬件级别的优化（例如 FlashAttention [240]）将变得非常重要，是提高 Transformer 架构效率的一个重要技术途径。

最近，长上下文窗口受到了广泛关注，现有的大语言模型通常能够支持较长的上下文窗口，例如 GPT-4 Turbo 支持 128K 的上下文，Claude 2.1 支持 200K 的上下文。虽然研究人员做了很多探索工作来增强大语言模型的长文本建模能力，但是仍然存在模型不能充分利用上下文窗口中信息的现象。为了解决这个问题，需要针对性调整模型架构或设计特定的训练算法来增强长文本信息的建模和利用。

另一个令人担忧的问题是，现有的工作主要集中在只有解码器的 Transformer 网络架构上。尽管这种架构的有效性得到了充分的验证，但是现有工作对于其他候选模型架构缺乏多元化的探索，从长远来看，这对于大语言模型的研发是不利的。在未来的工作中，需要更多相关研究关注语言模型架构的技术创新与核心突破，从而更好地推动大语言模型的研发进程。

模型训练

目前业界对于大语言模型的训练方法相对固定，主要是使用预测下一个词元的语言建模损失进行模型参数的优化，不同大语言模型之间的区别主要体现在如何准备与使用训练数据。因此，需要建立以数据为中心的训练体系架构与训练框架，从而完整打通数据采集、数据清洗、数据配比与数据课程的自动化（或半自动化）流程，这对于高效研发大语言模型具有非常重要的意义。

在实践研发中，大语言模型的训练需要巨大的算力开销，训练过程容易受到数据质量、训练技巧等方面的影响，将会面临着诸多的技术挑战。因此，需要总结与探索更系统化、更节约算力的预训练方法，充分考虑模型特点、学习效率和训练稳定性等多种因素。例如，可以采用基于控制变量的小模型沙盒实验对于上述因素进行验证与探索，但是也需要意识到很多基于小模型的结论可能无法迁移到

大模型上。进一步，还需要加强对于大规模计算资源的协同使用与有效调度，从而更好地组织和利用算力资源。

与传统模型的研发相比，大模型的训练过程通常需要花费更长的时间，需要针对性设计模型性能诊断方法（如 GPT-4 提出了可预测的训练方法 [35]），以便在训练过程中及早发现异常问题。由于从头开始训练大语言模型的成本很高，科研人员经常会使用已经公开发布的模型（如 LLaMA [34] 和 FLAN-T5 [41]）进行继续预训练或微调，这已经成为一种常见的大模型研发方式。在继续预训练或微调过程中，也需要设计合适的训练机制，注意解决灾难性遗忘、能力均衡、任务特化等问题。此外，由于大模型的训练数据在训练过程开始前就需要采集完毕，因此会出现信息过时、知识错误等问题，还需要研发有效的微调策略以注入或者修正某些特定知识，这一方向被称为“大模型编辑”或者“知识编辑” [360]。

模型使用

由于大语言模型微调成本很高，提示已经成为大语言模型的主要使用途径，即通过自然语言来表述待解决任务的任务需求。进一步，通过将任务描述与示例样本相结合的方式构建任务提示，上下文学习赋予了大语言模型对于新任务的学习与适应能力，在一些任务场景中，甚至能够超过微调模型的效果。为了提高大语言模型对于复杂任务的推理能力，研究人员还提出了一系列提示增强技术，例如将中间推理步骤纳入提示的思维链策略。此外，基于大模型的任务规划（Planning）也是一种解决复杂任务的有效方法，通过多次与大语言模型以及环境进行交互，从而以迭代提升的方式解决复杂任务。

尽管围绕提示学习的研究工作很多，但是与提示相关的若干基础问题还没有得到很好的解释：对于复杂任务，为什么好的提示可以诱导大模型输出正确答案，而一般的提示（对于任务的基本描述）却不能有效求解任务？高级的提示方法（如 ICL 和 CoT）的基础原理是什么，并如何被进一步改进？如何高效地为大语言模型找到特定任务的有效提示？这些问题都值得进行深入探索，对于理解大语言模型的内在机理具有重要意义。

在实践应用中，有效降低大语言模型的推理成本已经成为大语言模型大规模部署的重要挑战，如何有效压缩大模型的物理存储空间并且提升提示推理速度需要得到更多的研究关注。为了提升大语言模型的下游任务适配能力，检索增强生成（Retrieval-Augmented Generation, RAG）已经成为新任务、新数据场景下的一种较为通用的解决方案。通过检索增强，可以从领域数据集中进行相关内容的检索，

并将其加入到任务提示中。已有研究表明，检索增强可以有效扩展大语言模型的知识边界并提高其问答能力 [445]。然而，检索增强的效果还依赖于大模型的长文本理解与利用能力，需要进行专门的提升与适配 [446]。

安全性与对齐

尽管大语言模型具有较强的模型能力，但是它们也面临着很多安全挑战。例如，大语言模型存在生成幻觉内容的倾向 [350]，可能会输出存在事实性错误的文本。更严重的是，大语言模型可能会因为某些恶意指令生成有害或有偏见的内容，从而导致潜在的滥用风险 [23, 28]。关于大语言模型安全问题（如隐私问题、过度依赖、虚假信息和社会影响等）的详细讨论，读者可以参考 GPT-3/4 的技术报告 [23, 35]。

为了解决大模型的安全问题，基于人类反馈的强化学习（RLHF）[28] 方法已经成为了主要的技术途径之一，该方法将人工标注纳入训练过程来加强大模型对于人类价值观的对齐。在 RLHF 过程中，还可以加入与安全相关的提示，从而针对性地消除大模型的安全风险。然而，RLHF 的成功训练在很大程度上依赖专业标注人员提供高质量的反馈数据，因此在实践中难以被广泛使用。为了解决这一问题，需要对于 RLHF 方法进行相关改进，以减少人工标注者的工作量，也需要寻求更为高效、可大规模部署的高质量数据标注方法，例如，可以使用大语言模型来辅助标注工作。此外，还可以开发实现更为简单的对齐优化算法（如 DPO 等）[29]，以去除 RLHF 中强化学习算法的训练难度与不稳定性，这也成为了一个重要的研究方向。

作为另一种实践方法，红队攻击（Red Teaming）方法被广泛用于提高大语言模型的安全性，它利用收集的对抗性提示（也就是有害提示）来帮助大语言模型抵御恶意攻击。随着大语言模型的广泛应用，在使用特定领域的数据对进行微调时，隐私保护也成为了一个值得关注的研究问题，联邦学习 [447] 是解决隐私受限场景下大模型应用的可行技术路径。

应用生态

本次大模型的热潮由 ChatGPT 的上线而掀起，通过自由的自然语言对话形式，ChatGPT 向网络用户展现了大语言模型的强大能力。由于大语言模型在知识利用、复杂推理、工具利用等方面具有优异的模型性能，在实践中具备解决各种任务的潜在能力，对于下游应用将会产生重要的影响。

首先，大语言模型对于以搜索引擎与推荐系统为代表的信息获取技术产生了

重要影响。类 ChatGPT 形式的信息助手突破了传统搜索引擎的限制，为用户提供了一种新的信息获取途径；New Bing 将大语言模型集成到搜索系统中，实现了检索与生成方式相结合的信息获取技术。

其次，以大语言模型为中枢核心的应用软件系统将得到广泛发展，通过借助大模型的任务规划与工具使用能力，将能够整合多业务的解决方案，形成复杂业务系统的统一技术路径。本次技术革新将会催生一个由大语言模型赋能的、与我们生活息息相关的应用生态系统。作为一个典型的技术应用范式，大语言模型智能体受到了广泛的关注与应用，通过分析目标任务、制定解决方案并且执行相应方案，能够自主地完成复杂任务的求解，还可以通过多智能体组成的自组织系统来模拟或者解决更为复杂的任务场景。

最后，大语言模型的兴起为通用人工智能的探索带来了新的研究曙光，人类有望研发比以往任何时候都更强大、更通用的人工智能系统。同时，在这一发展过程中，研究人员也应该关注人工智能的安全发展，使得人工智能能够真正为人类造福，推动人类社会发展。